

Национальный исследовательский университет
«Высшая школа экономики»

Факультет экономических наук

Эконометрика

**Эмпирическая оценка влияния загрязнения воздуха на ожидаемую
продолжительность жизни в регионах Российской Федерации**

Выполнили:

Ковалёва Мария Сергеевна
Кутузов Иван Владимирович
Николук Татьяна Николаевна

Преподаватель семинаров:

Бывальцева-Станкевич Анастасия Александровна

Москва, 2026

Использование генеративных ИИ-моделей

При подготовке работы генеративные ИИ-инструменты использовались как вспомогательное средство: для проверки логики спецификаций, редактуры формулировок, написания и отладки кода в нутбуке, а также для технической подготовки L^AT_EX-таблиц. Содержательная постановка темы, выбор данных и финальная интерпретация результатов были проверены авторами работы.

1. Введение и исследовательский вопрос

Загрязнение атмосферного воздуха является важным фактором риска для здоровья населения. В медицинской и экономической литературе оно связывается с ростом сердечно-сосудистой, респираторной и онкологической смертности, а значит, потенциально влияет и на ожидаемую продолжительность жизни. Для России этот вопрос особенно актуален из-за высокой региональной неоднородности: субъекты РФ заметно различаются по промышленной структуре, уровню добычи полезных ископаемых, энергетике, плотности населения и социально-экономическим условиям.

Цель работы — оценить, связаны ли выбросы загрязняющих веществ от стационарных источников на душу населения с ожидаемой продолжительностью жизни в регионах РФ. Основная эмпирическая сложность состоит в потенциальной эндогенности загрязнения: оно может быть связано с ненаблюдаемыми характеристиками регионов, качеством инфраструктуры, отраслевой структурой и ошибками измерения. Поэтому наряду с OLS используется метод инструментальных переменных.

2. Гипотезы

В соответствии с proposal проверяются три содержательные гипотезы.

H1. Рост выбросов загрязняющих веществ на душу населения связан со снижением ожидаемой продолжительности жизни.

$$H_0 : \beta_1 = 0, \quad H_1 : \beta_1 < 0.$$

Ожидаемый знак коэффициента при `ln_emissions_h1_pc` отрицательный. Эта гипотеза согласуется с результатами Pope et al. (2002), Chen et al. (2013), Ebenstein et al. (2017), а также с российскими работами о связи загрязнения воздуха и смертности.

H2. Доход на душу населения положительно связан с ожидаемой продолжительностью жизни после контроля загрязнения и базовых региональных характеристик.

$$H_0 : \beta_{\text{grp}} = 0, \quad H_1 : \beta_{\text{grp}} > 0.$$

В proposal гипотеза была сформулирована с контролем на возрастную структуру. В финальной baseline-спецификации `age_struct_share` не включается как основной контроль: демографическая структура может частично отражать уже накопленные различия в смертности и миграции, поэтому её использование как полностью экзогенного контроля было бы слишком сильным допущением. Переменная оставлена только как проверка робастности.

H3. Занятость в добыче полезных ископаемых на душу населения положительно связана с загрязнением воздуха.

$$H_0 : \pi_1 = 0, \quad H_1 : \pi_1 > 0.$$

Эта гипотеза является проверкой релевантности основного инструмента `ln_emp_mining_pc`. Добывающие регионы в среднем должны иметь более высокие стационарные выбросы, однако сила инструмента должна проверяться эмпирически.

Во всех таблицах ниже используются стандартные двусторонние p-value, хотя содержательные гипотезы имеют направленный характер. Это стандартный формат отчётности для регрессионных таблиц

и диагностических тестов.

3. Данные и изменения после proposal

Используются кросс-секционные данные по 85 субъектам РФ за 2015 год. Основной источник данных — Росстат/Fedstat. Зависимая переменная `life_expectancy` измеряет ожидаемую продолжительность жизни в годах. Основная объясняющая переменная `ln_emissions_h1_pc` — логарифм выбросов загрязняющих веществ от стационарных источников на душу населения. В качестве основного инструмента используется `ln_emp_mining_pc` — логарифм занятости в добыче полезных ископаемых на душу населения.

В финальной версии были внесены три важных уточнения относительно proposal.

1. **Проверка автономных округов.** В одной из промежуточных версий датасета Архангельская область и Тюменская область были записаны как региональные totals «с АО», тогда как Ненецкий АО, Ханты-Мансийский АО и Ямало-Ненецкий АО также присутствовали отдельными строками. Это создавало риск двойного счёта. В финальном ноутбуке используется исправленная версия, где Архангельская область и Тюменская область берутся без автономных округов. Например, население Архангельской области в финальном датасете равно 1,094,549, а Тюменской области — 1,462,199; автономные округа остаются отдельными наблюдениями.
2. **Возрастная структура.** `age_struct_share` не включается в preferred baseline, поскольку демографическая структура может быть outcome-related: высокая или низкая доля отдельных возрастных групп может отражать прошлую смертность, миграцию и региональную селекцию. Поэтому она используется только в robustness specification.
3. **Обращаемость в медучреждения.** `visits_per_capita` не включается в baseline. Эта переменная может отражать не только доступность медицины, но и текущую заболеваемость, то есть сама быть связанной с результатом. Кроме того, как proxy качества здравоохранения она достаточно шумная.

Переменная `region` используется только как идентификатор наблюдений и не включается в модели как категориальный регрессор.

Таблица 1: Дескриптивные статистики основных переменных

Переменная	Среднее	Ст. откл.	Мин.	Медиана	Макс.
<code>life_expectancy</code>	70,554	2,394	63,140	70,390	78,470
<code>ln_emissions_h1_pc</code>	-10,336	1,393	-14,516	-10,262	-6,996
<code>ln_emp_mining_pc</code>	-5,571	1,655	-8,734	-5,903	-1,526
<code>ln_grp_pc</code>	5,834	0,672	4,683	5,769	8,587
<code>urban_share</code>	70,086	13,247	29,900	71,300	100,000
<code>ln_population_avg</code>	13,960	0,971	10,655	13,989	16,323
<code>age_struct_share</code>	58,047	2,145	50,900	57,700	64,900

4. Модель и метод оценивания

Базовая модель оценивается методом OLS:

$$\begin{aligned} \text{life_expectancy}_i = & \beta_0 + \beta_1 \text{ln_emissions_h1_pc}_i + \beta_2 \text{ln_grp_pc}_i \\ & + \beta_3 \text{urban_share}_i + \beta_4 \text{ln_population_avg}_i + \varepsilon_i. \end{aligned} \quad (1)$$

Preferred baseline включает три контроля: `ln_grp_pc`, `urban_share`, `ln_population_avg`.

Все стандартные ошибки в OLS оцениваются как HC1-robust.

Поскольку загрязнение может быть эндогенным, дополнительно оценивается 2SLS. Первая ступень:

$$\ln_emissions_h1_pc_i = \pi_0 + \pi_1 \ln_emp_mining_pc_i + \pi_2 \ln_grp_pc_i + \pi_3 urban_share_i + \pi_4 \ln_population_avg_i + v_i. \quad (2)$$

Вторая ступень:

$$life_expectancy_i = \beta_0 + \beta_1 \widehat{\ln_emissions_h1_pc}_i + \beta_2 \ln_grp_pc_i + \beta_3 urban_share_i + \beta_4 \ln_population_avg_i + u_i. \quad (3)$$

Инструмент $\ln_emp_mining_pc$ выбран как основной, потому что занятость в добыче связана с отраслевой структурой и географией ресурсов, а не напрямую с текущими индивидуальными исходами здоровья. При этом exclusion restriction не является механически гарантированным, поэтому причинная интерпретация формулируется осторожно.

5. Основные результаты

Таблица 2: Baseline OLS и 2SLS

	OLS	2SLS
$\ln_emissions_h1_pc$	-1,2065*** (0,2082)	-1,5840*** (0,4802)
$\ln_grp_pc$	1,8119*** (0,5004)	2,2909*** (0,8110)
$urban_share$	-0,0474*** (0,0152)	-0,0451*** (0,0153)
$\ln_population_avg$	1,0276*** (0,2444)	0,9672*** (0,2323)
Constant	36,4870*** (4,9334)	30,4784*** (9,7992)
Observations	85	85
R^2	0,5169	0,4900
Robust SE	HC1	robust, debiased

Примечание: в скобках робастные стандартные ошибки. *** $p < 0,01$.

В OLS коэффициент при загрязнении отрицателен и статистически значим: -1,2065. Это означает, что удвоение выбросов от стационарных источников на душу населения связано примерно со снижением ОПЖ на $1,2065 \cdot \ln 2 \approx 0,84$ года. В 2SLS оценка по модулю больше: -1,5840, что соответствует снижению примерно на 1,10 года при удвоении выбросов. Такой знак согласуется с H1 и с литературой о вреде долгосрочного воздействия загрязнения воздуха.

Коэффициент при $\ln_grp_pc$ положителен и значим в обеих baseline-спецификациях. Это поддерживает H2: при прочих равных более высокий региональный доход связан с большей ожидаемой продолжительностью жизни. Важно, что этот вывод относится к baseline без age_struct_share ; возрастная структура проверяется отдельно, чтобы не смешивать контроль с потенциально outcome-related переменной.

6. Первая ступень и reduced form

Таблица 3: Первая ступень и reduced form

	Первая ступень ln_emissions_h1_pc	Reduced form life_expectancy
ln_emp_mining_pc	0,3035*** (0,1038)	−0,4808*** (0,1706)
ln_grp_pc	0,7797**	1,0559
urban_share	0,0111	−0,0626**
ln_population_avg	−0,0649	1,0700***
Observations	85	85
F-statistic for instrument	8,5414	—
p-value	0,0045	0,0048

Примечание: первая ступень оценена с HC1 standard errors.

Первая ступень показывает положительную и статистически значимую связь добычи с выбросами: $\hat{\pi}_1 = 0,3035$, $p = 0,0035$ – $0,0045$ в зависимости от реализации теста. Это поддерживает H3 как условие релевантности инструмента. Однако $F = 8,54$ находится около распространённого правила большого пальца $F > 10$ и ниже более строгих ориентиров Stock–Yogo. Поскольку используются robust covariance estimates, сравнение с классическими порогами Stock–Yogo следует трактовать эвристически. Поэтому инструмент лучше описывать как умеренно сильный или пограничный, но не как однозначно сильный.

Reduced form также имеет ожидаемый знак: регионы с большей занятостью в добыче имеют более низкую ОПЖ после тех же контролей ($-0,4808$, $p = 0,0048$). Это согласуется с общей IV-логикой, но не доказывает exclusion restriction.

7. Диагностические тесты

Таблица 4: Сводка диагностических тестов

Тест	H0	Статистика	p-value	Вывод
First stage relevance	$\pi_1 = 0$	$F(1, 80) = 8,5414$	0,0045	H0 отвергается
Wu–Hausman	загрязнение экзогенно	$F(1, 79) = 0,6806$	0,4119	H0 не отвергается
Durbin	загрязнение экзогенно	$\chi^2(1) = 0,7260$	0,3942	H0 не отвергается
Sargan	restrictions hold	$\chi^2(1) = 0,8726$	0,3502	H0 не отвергается

Wu–Hausman и Durbin с preferred mining-IV не отвергают экзогенность ln_emissions_h1_pc. Это не означает, что экзогенность доказана: при $N = 85$ и пограничной силе инструмента тест может иметь ограниченную мощность. Поэтому результат интерпретируется как смешанное evidence on endogeneity. В базовой работе OLS остаётся полезной описательной оценкой, а 2SLS — осторожной попыткой учесть потенциальную эндогенность.

VIF-анализ не указывает на серьёзную мультиколлинеарность между регрессорами baseline: для всех объясняющих переменных VIF находится примерно в диапазоне 1,18–2,18. Тест Саргана применяется только в сверхидентифицированной спецификации с mining и energy instruments. H0 не отвергается

($p = 0,3502$), но это не доказывает валидность инструментов, особенно если потенциальное нарушение exclusion restriction у инструментов имеет похожую природу.

8. Влиятельные наблюдения и робастность

Отдельно проверялись leverage и Cook's distance. Baseline-оценки сохраняют все 85 наблюдений: регионы с высокой добычей и малыми населенными являются содержательно важной частью вариации, а не техническими ошибками. Наблюдения только помечаются в диагностике; удаление используется как robustness-check.

Наиболее влиятельным наблюдением является Ненецкий автономный округ. После исправления проблемы АО double counting его Cook's distance равен 0,9614, leverage равен 0,4960. Это близко к стро-
гому порогу Cook's $D > 1$ и существенно выше правила $4/n = 0,0471$. Высокое влияние объясняется малым населением и экстремальными per-capita показателями добычи и выбросов.

Таблица 5: Robustness: возрастная структура и Ненецкий АО

Спецификация	N	OLS beta	OLS p	IV beta	IV p
Preferred baseline	85	-1,2065	0,0000	-1,5840	0,0015
Добавлен age_struct_share	85	-1,1735	0,0000	-1,6058	0,0008
Leave-one-out: Ненецкий АО	84	-1,0861	0,0000	-1,4711	0,0026

Добавление переменной возрастной структуры и исключение Ненецкого АО не меняют основной знак результата: оценка эффекта загрязнения остаётся отрицательной и статистически значимой. Однако age_struct_share не интерпретируется как чистый экзогенный демографический контроль; это именно проверка чувствительности.

9. Альтернативные инструменты

Дополнительно были проверены ln_emp_energy_pc и ln_emissions_fuel_pc. Эти инструменты могут быть более релевантными статистически, но экономически слабее с точки зрения exclusion restriction. Выбросы от сжигания топлива механически связаны с загрязнением и могут напрямую входить в pollution channel. Занятость в энергетике может влиять на ОПЖ не только через загрязнение, но и через доходы, инфраструктуру, структуру городов и качество рабочих мест. Поэтому они не рассматриваются как preferred instruments.

Таблица 6: Robustness: альтернативные инструменты

Инструменты	IV beta	SE	First-stage F	Wu p
ln_emp_mining_pc	-1,5840	0,4802	8,5414	0,4119
ln_emp_energy_pc	-2,0811	0,5312	8,5632	0,0091
ln_emissions_fuel_pc	-2,0553	0,3087	69,2192	0,0000
Mining + energy	-1,9251	0,4267	5,2412	0,0128

Альтернативные инструменты дают тот же отрицательный знак для влияния загрязнения, но не должны использоваться как главный аргумент в пользу причинной интерпретации. Особенно сильная first stage у ln_emissions_fuel_pc не делает инструмент более убедительным: наоборот, его механическая близость к загрязнению делает exclusion restriction более сомнительным. Поэтому предпочтительным остаётся ln_emp_mining_pc, а результаты с альтернативными инструментами трактуются как дополнительная проверка устойчивости знака.

10. Выводы по гипотезам

Таблица 7: Итоги проверки гипотез

Гипотеза	Проверка	Вывод
H1: рост выбросов связан со снижением ОПЖ	OLS beta = $-1,2065$, 2SLS beta = $-1,5840$, оба p-value < 0,01	Поддерживается по знаку и значимости; причинная интерпретация осторожная
H2: доход положительно связан с ОПЖ	OLS beta for <code>ln_grp_pc</code> = $1,8119$, 2SLS beta = $2,2909$, оба p-value < 0,01	Поддерживается в baseline; возрастная структура только robustness
H3: добыча связана с выбросами	$\hat{\pi}_1 = 0,3035$, $F = 8,5414$, $p = 0,0045$	Relevance поддерживается, но сила инструмента пограничная/умеренная

Основной результат работы состоит в том, что более высокие выбросы от стационарных источников на душу населения устойчиво связаны с более низкой ожидаемой продолжительностью жизни в регионах РФ. Знак сохраняется в OLS, baseline 2SLS, спецификации с возрастной структурой и leave-one-out проверке без Ненецкого АО. По масштабу baseline 2SLS предполагает, что удвоение выбросов связано со снижением ОПЖ примерно на 1,1 года.

Тем не менее результаты не следует формулировать как окончательное доказательство причинного эффекта. Инструмент `ln_emp_mining_pc` выглядит статистически релевантным и экономически более правдоподобным, чем альтернативные инструменты, но его сила не является бесспорно высокой. Тесты Wu–Hausman и Durbin не отвергают экзогенность загрязнения для preferred instrument, тогда как более статистически сильные альтернативные инструменты сами более сомнительны экономически. Поэтому корректный вывод: evidence is mixed, отрицательная связь хорошо поддерживается данными, но причинная интерпретация должна оставаться осторожной.

Список литературы

- Pope, C. A., Burnett, R. T., Thun, M. J., Calle, E. E., Krewski, D., Ito, K., Thurston, G. D. (2002). Lung cancer, cardiopulmonary mortality, and long-term exposure to fine particulate air pollution. *JAMA*.
- Chen, Y., Ebenstein, A., Greenstone, M., Li, H. (2013). Evidence on the impact of sustained exposure to air pollution on life expectancy from China's Huai River policy. *PNAS*.
- Ebenstein, A., Fan, M., Greenstone, M., He, G., Zhou, M. (2017). New evidence on the impact of sustained exposure to air pollution on life expectancy from China's Huai River Policy. *PNAS*.
- Preston, S. H. (1975). The changing relation between mortality and level of economic development. *Population Studies*.
- Ревич Б. А., Быков А. А. (1998). Загрязнение воздуха как фактор смертности в городах России.
- Reshetin, V. P., Kazazyan, V. I. (2004). Public-health impact of outdoor air pollution in Russia.
- Greenstone, M. (2002). The impacts of environmental regulations on industrial activity: Evidence from the 1970 and 1977 Clean Air Act Amendments.
- Chay, K. Y., Greenstone, M. (2003). Air quality, infant mortality, and the Clean Air Act of 1970.