

Федеральное государственное автономное образовательное учреждение высшего образования

НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ

«ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»

Факультет экономических наук

Дисциплина «Машинное обучение в экономике»

**Причинный анализ влияния премиум-подписки на траты
клиентов платформы доставки**

Выполнили:

Сячинова Екатерина

Мягких Варвара

Ковалёва Мария

3 курс, группа БЭК2310

Москва, 2026 г.

Содержание

Блок 1. Обоснование темы	2
Задание 1.1	2
Задание 1.2	3
Задание 1.3	3
Задание 1.4	4
Задание 1.5	5
Задание 1.6	5
Блок 2. Генерация и предварительная обработка данных	6
Задание 2.1	6
Задание 2.2	8
Задание 2.3	9
Задание 2.4	10
Блок 3. Классификация	11
Задание 3.1	12
Задание 3.2	13
Задание 3.3	16
Задание 3.4	18
Задание 3.5	20
Задание 3.6	20
Задание 3.7	21
Задание 3.8	24
Задание 3.9	28
Задание 3.10. Повышенная сложность	29
Задание 3.11	30
Блок 4. Регрессия	33
Задание 4.1	33
Задание 4.2	34
Задание 4.3	36
Задание 4.2, повышенная сложность	37
Задание 4.4, повышенная сложность	38
Задание 4.5	39
5 Эффекты воздействия	40
5.1	41
5.2	41
5.3	43
5.4	44
5.5	49
5.6	53
5.7	56
5.8	57
5.9	59

Блок 1. Обоснование темы

Задание 1.1

Придумайте непрерывную зависимую (целевую) переменную и эндогенную бинарную переменную воздействия. Обоснуйте, почему переменная воздействия может быть эндогенной и, в соответствии с приведенным обоснованием, создайте хотя бы одну дополнительную ненаблюдаемую переменную, которая коррелирует и с целевой переменной, и с переменной воздействия.

Ответ

В работе изучается влияние премиум-подписки на сервис доставки на месячные траты клиента внутри платформы доставки. Содержательно речь идет о подписке, которая снижает для клиента транзакционные издержки заказа: доставка становится дешевле, быстрее или удобнее, а дополнительные привилегии делают повторные заказы менее затратными с точки зрения денег и времени.

Зависимая переменная исследования - `monthly_spending`, то есть месячные траты клиента в сервисе доставки. Это непрерывная денежная величина: она отражает общий объем покупок клиента за месяц и поэтому подходит для задач регрессии и оценки эффектов воздействия. В обозначениях ниже это Y_i .

Эндогенная бинарная переменная воздействия - `premium_subscription`, бинарный индикатор оформления премиум-подписки. Значение 1 означает, что клиент оформил подписку, значение 0 - что не оформил. В обозначениях ниже это $D_i \in \{0, 1\}$. Главный исследовательский вопрос: увеличивает ли наличие премиум-подписки месячные траты клиента, и если да, насколько велик этот эффект.

Эта тема экономически содержательна, потому что подписочные программы стали одним из ключевых инструментов удержания клиентов в цифровой коммерции. Для платформ доставки подписка может менять не только вероятность повторного заказа, но и частоту заказов, средний чек, чувствительность к стоимости доставки и лояльность к платформе.

Премиум-подписка не назначается клиентам случайно: клиент сам принимает решение, оформлять ее или нет. Это свидетельствует о такой причине эндогенности, как самоотбор. Поэтому простое сравнение средних трат подписчиков и неподписчиков не дает причинный эффект подписки. Более активные клиенты могут заранее понимать, что будут часто пользоваться доставкой, и поэтому чаще оформлять подписку. В таком случае высокие траты после оформления подписки частично объясняются не самой подпиской, а исходной склонностью клиента часто покупать онлайн.

Для отражения этой проблемы в процессе генерации вводится ненаблюдаемая переменная `online_preference` - склонность клиента к онлайн-покупкам. Она не включается в итоговый набор признаков, но участвует в генерации данных. Клиенты с высокой `online_preference` одновременно:

- чаще оформляют премиум-подписку, потому что заранее ожидают большую выгоду от бесплатной или более удобной доставки;
- больше тратят в сервисе доставки, потому что в целом предпочитают онлайн-заказы офлайн-покупкам.

Именно такая скрытая склонность создает эндогенность: `premium_subscription` коррелирует с ненаблюдаемым фактором, который также влияет на `monthly_spending`. В сгенерированных данных это выполняется: $\text{Corr}(D_i, \text{OnlinePreference}_i) = 0.220$, а $\text{Corr}(Y_i, \text{OnlinePreference}_i) = 0.462$.

Формально причинная история задается так:

$$\text{OnlinePreference}_i \rightarrow D_i, \quad \text{OnlinePreference}_i \rightarrow Y_i.$$

В терминах эконометрики возникает самоотбор в воздействие, а наивная разница средних между подписчиками и неподписчиками смешивает причинный эффект подписки и различия в типах клиентов.

Задание 1.2

Опишите, для чего может быть полезно изучение влияния переменной воздействия на зависимую переменную. В частности, укажите, как эта информация может быть использована бизнесом или государственными органами.

Ответ

Для бизнеса оценка эффекта премиум-подписки на месячные траты нужна для принятия решений о дизайне подписочной программы. Если подписка действительно увеличивает траты, платформа может обосновать инвестиции в бесплатную доставку, персональные предложения, пробные периоды и удержание подписчиков. При этом важно отличать реальный прирост от самоотбора: если подписку оформляют только клиенты, которые и так много тратили бы, то агрессивное продвижение подписки может быть менее прибыльным, чем кажется по простому сравнению средних.

Результаты такого исследования могут использоваться для:

- расчета окупаемости премиум-подписки и бесплатных пробных периодов;
- выбора сегментов клиентов, которым стоит показывать предложение о подписке;
- оценки того, увеличивает ли подписка общий объем заказов или только перераспределяет уже существующие покупки;
- настройки ценовой политики, лимитов бесплатной доставки и персональных промоакций;
- анализа риска каннибализации выручки от доставки.

Для государственных органов и регуляторов такая тема также имеет значение. Подписочные модели могут усиливать рыночную власть крупных платформ, менять потребительское поведение и создавать эффекты привязки клиента к одному сервису. Поэтому причинная оценка влияния подписки полезна для анализа конкуренции на цифровых рынках, оценки прозрачности подписочных условий и изучения того, как платформенные механики влияют на расходы домохозяйств.

Задание 1.3

Обоснуйте наличие причинно-следственной связи между зависимой переменной и переменной воздействия. Кратко опишите результаты не менее двух предшествующих исследований из научной литературы, подкрепляющих ваши предположения. Критически оцените методологию этих работ и объясните, в чем преимущества и недостатки применяемых вами методов по сравнению с теми, что использовались в этих исследованиях.

Ответ

Предполагаемая причинная связь состоит в том, что премиум-подписка снижает предельную стоимость дополнительного заказа и делает использование сервиса более удобным. После оплаты подписки клиент может воспринимать каждую следующую доставку как более дешевую, а значит чаще заказывать и переносить часть покупок внутрь платформы. Дополнительно может работать эффект привязки: если клиент уже заплатил за подписку, ему рациональнее использовать именно этот сервис, чтобы использовать преимущества подписки.

Эта логика согласуется с эмпирическими исследованиями электронной коммерции и подписочных программ. Michael Lewis (2006) в статье *The Effect of Shipping Fees on Customer Acquisition, Customer Retention, and Purchase Quantities*, опубликованной в *Journal of Retailing*, показывает, что структура платы за доставку влияет на привлечение клиентов, удержание и объем заказов. Это подтверждает важный механизм нашей темы: стоимость доставки и связанные с ней стимулы способны менять покупательское поведение, а не являются только технической комиссией.

Guo and Liu (2023) в статье *The Effectiveness of Membership-Based Free Shipping: An Empirical Investigation of Consumers' Purchase Behaviors and Revenue Contribution*, опубликованной в *Journal of Marketing*, изучают membership-based free shipping и показывают, что подписка не обязательно сразу увеличивает расходы среднего клиента: в начале покупатели могут разбивать крупные заказы на меньшие. Однако со временем членство способно усиливать привязку к платформе, увеличивать частоту покупок, разнообразие заказов и вклад в выручку; при этом эффект неоднороден по сегментам клиентов. Это особенно близко к нашему сюжету, потому что премиум-подписка в сервисе доставки также снижает стоимость повторных заказов и может укреплять связь клиента с платформой.

Iyengar, Park and Yu (2022) в статье *The Impact of Subscription Programs on Customer Purchases*, опубликованной в *Journal of Marketing Research*, также находят, что подписочные программы могут приводить к значимому и устойчивому росту покупок; при этом эффект объясняется не только прямой экономической выгодой, но и неэкономическими механизмами, связанными с вовлеченностью и восприятием ценности подписки. Для нашей постановки это важно: подписка может воздействовать не только через формальное снижение цены доставки, но и через изменение привычек и частоты использования сервиса.

Методологически эти работы сильны тем, что используют реальные данные о поведении клиентов и стремятся отделить эффект подписки или доставки от обычных различий между клиентами. Однако даже в таких исследованиях центральной проблемой остается самоотбор: клиенты, которые оформляют подписку, могут отличаться от остальных еще до оформления. В нашей работе эта проблема задается явно через ненаблюдаемую переменную `online_preference`, а затем используется инструментальная переменная `free_trial_banner`, чтобы отделить вариацию подписки, вызванную внешним стимулом, от исходной активности клиента.

Преимущество нашей симуляционной постановки состоит в том, что истинные потенциальные исходы известны: можно сравнить наивную оценку с истинными ATE и LATE, а затем проверить, насколько методы машинного обучения и эконометрики приближаются к правильному эффекту. Недостаток симуляции состоит в том, что данные искусственные и не могут полностью воспроизвести поведение реальных клиентов. Поэтому сила работы не в доказательстве конкретного бизнес-эффекта для одной компании, а в аккуратной демонстрации причинной логики, эндогенности и способов ее корректировки.

Задание 1.4

Придумайте хотя бы три контрольные переменные, по крайней мере одна из которых должна быть бинарной и хотя бы одна - непрерывной. Кратко обоснуйте выбор каждой из них.

Ответ

В финальной версии генерации используются четыре наблюдаемые контрольные переменные.

`income` - доход клиента. Доход отражает платежеспособность: клиенты с более высоким доходом могут чаще пользоваться доставкой и легче оплачивать подписку. Переменная непрерывная и генерируется как логнормальная, что соответствует правосторонней асимметрии доходов.

`age` - возраст клиента. Возраст связан со стадией жизненного цикла, цифровыми привычками и структурой потребления. Молодые и средневозрастные клиенты могут активнее использовать онлайн-сервисы, но зависимость не обязана быть линейной, поэтому в генерации используются нелинейные возрастные компоненты.

`urban_area` - бинарный индикатор проживания в крупном городе. В крупных городах выше доступность доставки, шире выбор ресторанов и магазинов, быстрее логистика, поэтому и вероятность подписки, и месячные траты могут быть выше.

`family_size` - размер семьи. Большие домохозяйства потенциально делают более крупные и частые заказы, поэтому размер семьи влияет на объем трат и привлекательность подписки. Эта переменная также позволяет

задать содержательные взаимодействия, например более высокий спрос на доставку у городских семей.

Такой набор соответствует требованию задания: есть не менее трех контрольных переменных, среди них есть непрерывные переменные (income, age) и бинарная переменная (urban_area).

Задание 1.5

Придумайте бинарную инструментальную переменную и обоснуйте, почему она удовлетворяет необходимым условиям.

Ответ

Инструментальная переменная - free_trial_banner, бинарный индикатор показа клиенту баннера с предложением бесплатного пробного периода премиум-подписки. Идея инструмента состоит в том, что баннер повышает вероятность оформления подписки, но сам по себе не должен напрямую менять месячные траты клиента, кроме канала через подписку.

Условие релевантности выполняется содержательно: клиент, увидевший предложение бесплатного пробного периода, с большей вероятностью попробует премиум-подписку. В финальной генерации это дополнительно проверяется количественно: $Corr(premium_subscription, free_trial_banner) = 0.226$, то есть корреляция попадает в рекомендованный консультацией диапазон от 0.20 до 0.80 по модулю.

Условие исключения формулируется следующим образом: баннер не рекламирует конкретные товары, рестораны или скидки на заказы, а сообщает только о возможности попробовать подписку. Поэтому его прямой эффект должен идти через изменение вероятности подписки, а не через самостоятельное увеличение трат. В генерации вероятность показа баннера зависит только от наблюдаемых характеристик клиента, а не от скрытой online_preference. Следовательно, после контроля наблюдаемых характеристик инструмент можно интерпретировать как внешний источник вариации в подписке.

Условие монотонности также встроено в симуляцию: показ баннера может повысить вероятность подписки, но не должен заставлять клиента отказаться от подписки, если без баннера он бы ее оформил. Поэтому в данных появляются Always takers, Never takers и Compliers, но отсутствуют Defiers. Это важно для дальнейшей интерпретации локального среднего эффекта воздействия LATE.

Задание 1.6

В случае необходимости приведите дополнительные содержательные комментарии о целях, задачах, методологии и вкладе вашего исследования.

Ответ

Итоговая логика исследования такова: премиум-подписка потенциально увеличивает месячные траты клиента, но ее оформление эндогенно из-за самоотбора более активных онлайн-покупателей. Чтобы воспроизвести эту проблему, в генерации создается скрытая переменная online_preference, влияющая и на подписку, и на траты. Чтобы затем иметь возможность корректировать эндогенность, вводится инструмент free_trial_banner, который влияет на подписку, но не входит напрямую в уравнение месячных трат.

Таким образом, выбранная тема соответствует требованиям задания: зависимая переменная непрерывная, переменная воздействия бинарная и эндогенная, ненаблюдаемый фактор содержательно обоснован, контрольные переменные экономически интерпретируемы, а инструментальная переменная имеет понятную бизнес-интерпретацию и проверяемую релевантность в сгенерированных данных.

Блок 2. Генерация и предварительная обработка данных

Задание 2.1

Опишите математически предполагаемый вами процесс генерации данных: распределения экзогенных переменных с конкретными параметрами; потенциальные исходы переменной воздействия в зависимости от значения инструмента и связь с наблюдаемым воздействием; потенциальные исходы зависимой переменной в зависимости от наличия воздействия и связь с наблюдаемым значением.

Ответ

Тема исследования: влияние премиум-подписки на сервис доставки на месячные траты клиента.

Зависимая переменная: `monthly_spending` - месячные траты клиента в сервисе доставки. В обозначениях ниже это Y_i .

Переменная воздействия: `premium_subscription` - оформил ли клиент премиум-подписку. В обозначениях ниже это $D_i \in \{0, 1\}$.

Инструментальная переменная: `free_trial_banner` - был ли клиенту показан баннер с предложением бесплатного пробного периода. В обозначениях ниже это $Z_i \in \{0, 1\}$.

Ненаблюдаемая переменная: `online_preference` - склонность клиента к онлайн-покупкам. В обозначениях ниже это $OnlinePreference_i$. Она влияет и на вероятность оформить подписку, и на общий объем трат, поэтому создает эндогенность.

В этой симуляции задается следующая причинная история:

$$OnlinePreference_i \rightarrow D_i, \quad OnlinePreference_i \rightarrow Y_i, \quad Z_i \rightarrow D_i \rightarrow Y_i.$$

Распределения экзогенных переменных

Контрольные переменные задаются так:

$$\begin{aligned} Income_i &= \exp(V_i), \quad V_i \sim N(11.10, 0.50^2), \\ Age_i^* &\sim N(35, 10^2), \quad Age_i = \text{round}(\min(70, \max(18, Age_i^*))), \\ Urban_i &\sim \text{Bernoulli}(0.70), \\ P(FamilySize_i = 1, 2, 3, 4, 5) &= (0.20, 0.35, 0.25, 0.15, 0.05). \end{aligned}$$

Скрытая склонность к онлайн-покупкам генерируется в два шага:

$$\begin{aligned} OnlinePreferenceRaw_i &\sim N(0, 1), \\ OnlinePreference_i &= F_{\text{logistic}}(OnlinePreferenceRaw_i). \end{aligned}$$

Итоговая `online_preference` лежит в интервале от 0 до 1 и не включается в наблюдаемый датасет.

Инструментальная переменная

Инструмент `free_trial_banner` показывает, был ли клиенту предложен бесплатный пробный период премиум-подписки. Вероятность показа баннера строится через индекс, зависящий только от наблюдаемых характеристик:

$$\begin{aligned} Z_i^* &= -0.75 + 4(0.15Income_i Z_i + 0.08Urban_i - 0.07AgeCenter_i - 0.06(FamilySize_i - 2.50)), \\ P(Z_i = 1 | X_i) &= \Phi(Z_i^*), \quad Z_i \sim \text{Bernoulli}(\Phi(Z_i^*)). \end{aligned}$$

Здесь $\Phi(\cdot)$ - функция распределения стандартного нормального закона. Ненаблюдаемая `online_preference` в индекс инструмента не входит, поэтому содержательно сохраняется условие исключения: баннер должен влиять на траты только через подписку.

В финальной симуляции $Var(Z_i^*) = 0.526$. Для `norm.cdf` ориентиром является дисперсия стандартной нормали, равная 1; по консультации отличие должно быть не более чем в 2 раза. Значение попадает в допустимый диапазон примерно от 0.50 до 2.

Потенциальные исходы подписки

Переменная воздействия моделируется через потенциальные исходы подписки. Пусть $R_i \sim Uniform(0, 1)$, а $D_i(z)$ - потенциальное значение подписки при значении инструмента $Z_i = z$. Тогда

$$D_i(1) = I(R_i \leq F_{logistic}(\eta_i^D + 0.75 + 0.30Segment_i + 0.20I(IncomeZ_i > 0.50))),$$

$$D_i(0) = I(R_i \leq F_{logistic}(\eta_i^D)),$$

где η_i^D содержит влияние `online_preference`, дохода, возраста, города, размера семьи и их нелинейных взаимодействий. Наблюдаемая подписка связана с потенциальными значениями так:

$$D_i = Z_i D_i(1) + (1 - Z_i) D_i(0).$$

Так как надбавка к индексу при $Z_i = 1$ неотрицательна и используется один и тот же R_i , для каждого клиента выполняется $D_i(1) \geq D_i(0)$, то есть Defiers отсутствуют.

Средняя потенциальная доля подписки при показе баннера равна 0.604, без баннера - 0.437. Наблюдаемая доля подписки равна 0.494.

Потенциальные исходы зависимой переменной

Зависимая переменная `monthly_spending` строится через потенциальные исходы:

$$Y_i(0) = \max(1, g_{0i}^{obs}(X_i) + g_{0i}^{unobs}(OnlinePreference_i) + \varepsilon_{0i}),$$

$$Y_i(1) = \max(1, g_{1i}^{obs}(X_i) + g_{1i}^{unobs}(OnlinePreference_i) + \varepsilon_{1i}).$$

Случайные ошибки задаются так:

$$\varepsilon_{0i} \sim 1600 \cdot t(10), \quad \varepsilon_{1i} \sim 2200 \cdot t(8).$$

Для каждого режима $j \in \{0, 1\}$ используется разложение:

$$g_{ji} = g_{ji}^{obs}(X_i) + g_{ji}^{unobs}(OnlinePreference_i).$$

Для режима с подпиской наблюдаемая часть дополняется гетерогенным структурным эффектом подписки:

$$g_{1i}^{obs}(X_i) = g_{0i}^{obs}(X_i) + \tau_i(X_i, OnlinePreference_i).$$

Эффект подписки выше для городских клиентов, семей с большим размером, клиентов с высоким доходом и клиентов активного возраста. Поэтому DGP является нелинейным и допускает неодинаковые индивидуальные эффекты воздействия.

Наблюдаемая зависимая переменная определяется фактическим воздействием:

$$Y_i = D_i Y_i(1) + (1 - D_i) Y_i(0).$$

Нижняя граница равна 1, чтобы траты оставались положительными и в дальнейшем можно было корректно использовать MAPE в регрессионном блоке.

По консультации для каждого режима $j = 0, 1$ дисперсии ε_j , g_j , g_j^{obs} и g_j^{unobs} должны отличаться не более чем в 5 раз. В финальной симуляции отношение max/min равно 4.061 для $j = 0$ и 3.968 для $j = 1$, то есть требование выполняется.

Задание 2.2

Симулируйте данные в соответствии с предполагаемым процессом и приведите корреляционную матрицу, а также таблицу с описательными статистиками: для непрерывных переменных - выборочное среднее, стандартное отклонение, медиану, минимум и максимум; для бинарных переменных - долю и количество единиц.

Указания: необходимо сгенерировать не менее 1000 наблюдений; доля единиц не должна быть меньше 0.10 или больше 0.90 ни для одной бинарной переменной.

Ответ

Сгенерировано $n = 30000$ наблюдений, что больше минимально требуемых 1000. Итоговый наблюдаемый датасет содержит переменные:

$$df_i = (Y_i, D_i, Income_i, Age_i, Urban_i, FamilySize_i, Z_i).$$

Ненаблюдаемая $online_preference$, потенциальные исходы $Y_i(0)$, $Y_i(1)$, $D_i(0)$ и $D_i(1)$ не включаются в итоговый датасет как признаки.

Описательные статистики для непрерывных переменных

	mean	std	median	min	max
monthly_spending	9952.12	6539.10	8478.69	1	36871
income	75206	40050.10	66396.20	9890.31	505877
age	35.205	9.614	35	18	70

Доли и количества единиц для бинарных переменных

	count_ones	share_ones	requirement	выполняется
premium_subscription	14821	0.494	0.10-0.90	да
free_trial_banner	10166	0.339	0.10-0.90	да
urban_area	21044	0.701	0.10-0.90	да

Все бинарные переменные удовлетворяют ограничению задания: доля единиц находится в диапазоне от 0.10 до 0.90.

Проверка распределения family_size

	target	actual	abs_diff
1	0.20	0.203	0.0030
2	0.35	0.351	0.0012
3	0.25	0.248	0.0024
4	0.15	0.150	0.0004
5	0.05	0.049	0.0014

Фактическое распределение family_size близко к заданным вероятностям. Небольшие отклонения являются обычной выборочной вариацией при случайной генерации.

Релевантность инструмента через условные вероятности

free_trial_banner	P(D=0)	P(D=1)
0	0.587	0.413
1	0.348	0.652

Таблица показывает релевантность инструмента: $P(D = 1|Z = 1) = 0.652$ выше, чем $P(D = 1|Z = 0) = 0.413$. Баннер повышает вероятность подписки, но не делает ее детерминированной.

Типы клиентов по реакции на инструмент

	count	share
Always taker	13110	0.437
Never taker	11877	0.396
Complier	5013	0.167

В выборке есть Compliers (16.70%), для которых инструмент меняет статус подписки. Defiers отсутствуют, поэтому монотонность для LATE выполняется.

Корреляционная матрица

	monthly_spending	premium_subscription	income	age	urban_area	family_size	free_trial_banner
monthly_spending	1	0.746	0.432	-0.095	0.302	0.35	0.20
premium_subscription	0.746	1	0.229	-0.137	0.213	0.146	0.226
income	0.432	0.229	1	-0.0020	-0.0020	-0.0020	0.37
age	-0.095	-0.137	-0.0020	1	-0.0080	-0.0020	-0.161
urban_area	0.302	0.213	-0.0020	-0.0080	1	-0.0060	0.09
family_size	0.35	0.146	-0.0020	-0.0020	-0.0060	1	-0.176
free_trial_banner	0.20	0.226	0.37	-0.161	0.09	-0.176	1

Корреляционная матрица используется как описательная диагностика, а не как доказательство причинности. Для причинной интерпретации далее нужны потенциальные исходы, инструмент и методы оценки эффектов.

Задание 2.3

Разделите выборку на обучающую и тестовую. Тестовая выборка должна включать от 20% до 30% наблюдений.

Ответ

Выборка разделена на обучающую и тестовую в пропорции 75/25. Размер обучающей выборки: 22500 наблюдений. Размер тестовой выборки: 7500 наблюдений.

Доля тестовой выборки равна 0.25, то есть 25%. Это попадает в требуемый заданием диапазон от 20% до 30%.

Для воспроизводимости использован фиксированный `random_state = 123`. Итоговые файлы сохранены как `df.csv`, `df_train.csv` и `df_test.csv`, чтобы следующие блоки проекта использовали ту же сгенерированную выборку.

Задание 2.4

В случае необходимости проведите дополнительный анализ и приведите дополнительные комментарии о процессе генерации данных, описательных статистиках и т.д.

Ответ

Дополнительно проверены ключевые условия из консультации и внутренняя согласованность DGP.

Проверка корреляций

Желательный диапазон из консультации для корреляции воздействия со скрытой переменной и инструментом: от 0.20 до 0.80 по модулю.

- $Corr(D, OnlinePreference) = 0.220$, значение попадает в диапазон 0.20-0.80. Это подтверждает существенную эндогенность.
- $Corr(D, Z) = 0.226$, значение попадает в диапазон 0.20-0.80. Это подтверждает релевантность инструмента.

Проверка дисперсий структурных частей

По консультации внутри каждого режима $j = 0$ и $j = 1$ должно выполняться:

$$\frac{\max\{Var(\varepsilon_j), Var(g_j), Var(g_j^{obs}), Var(g_j^{unobs})\}}{\min\{Var(\varepsilon_j), Var(g_j), Var(g_j^{obs}), Var(g_j^{unobs})\}} \leq 5.$$

variance	
Var(eps0)	3215420.00
Var(g0)	8102300.00
Var(g0_obs)	6057030.00
Var(g0_unobs)	1995030.00
Var(eps1)	6610990.00
Var(g1)	26229300.00
Var(g1_obs)	15271500.00
Var(g1_unobs)	9832760.00

Для $j = 0$ отношение максимальной дисперсии к минимальной равно 4.061. Для $j = 1$ отношение равно 3.968. Оба значения меньше 5, поэтому консультационное ограничение выполняется.

Проверка нижней границы трат

metric	value
0 share_min_monthly_spending0	0.022
1 share_min_monthly_spending1	0.0092
2 share_zero_monthly_spending	0
3 min_monthly_spending	1
4 mean_monthly_spending	9952.12

Доля потенциальных трат, обрезанных на нижней границе 1, невелика: около 2.17% для monthly_spending0 и 0.92% для monthly_spending1. В наблюдаемой зависимой переменной нет нулей, а минимальное значение равно 1, поэтому последующее вычисление MAPE не будет сталкиваться с делением на ноль.

Предварительная проверка истинных эффектов в DGP

Эта проверка относится именно к качеству симуляции: поскольку данные искусственные, в DGP известны потенциальные исходы и можно заранее убедиться, что наивное сравнение подписчиков и неподписчиков действительно искажено самоотбором. Полноценный анализ эффектов воздействия проводится позднее в отдельном блоке, а здесь эти величины используются только как диагностика генерации.

Используемые величины определяются так:

$$\begin{aligned}TE_i &= Y_i(1) - Y_i(0), \\ATE &= E[Y_i(1) - Y_i(0)], \\LATE &= E[Y_i(1) - Y_i(0) \mid D_i(1) > D_i(0)], \\ATE_{naive} &= E[Y_i \mid D_i = 1] - E[Y_i \mid D_i = 0].\end{aligned}$$

	estimate
ATE	6292.96
LATE	6280.32
mean(CATE)	6279.19
ATE_naive	9760.32

Наивная оценка выше истинного эффекта, что подтверждает наличие самоотбора в подписку.

Итоговая диагностика

metric	value
0 share_premium_subscription	0.494
1 share_free_trial_banner	0.339
2 share_urban_area	0.701
3 Corr(D, Z)	0.226
4 Corr(D, online_preference)	0.22
5 P(D=1 Z=0)	
6 P(D=1 Z=1)	
7 ATE	6292.96
8 LATE	6280.32
9 ATE_naive	9760.32

Итоговая таблица подтверждает три ключевых условия: бинарные доли находятся в диапазоне 0.10-0.90, корреляции $\text{Corr}(D, Z)$ и $\text{Corr}(D, \text{online_preference})$ попадают в диапазон 0.20-0.80, а наивная оценка отличается от истинного эффекта из-за эндогенного выбора подписки.

Пропуски

Доля пропусков по всем переменным равна нулю, поэтому дополнительная обработка missing values перед следующими блоками не требуется.

Блок 3. Классификация

Здесь и в последующих разделах ненаблюдаемые переменные, сгенерированные ранее с целью создания эндогенной переменной воздействия, не включаются в качестве признаков ни в одну из моделей.

В каждом из заданий, если не сказано иного, необходимо использовать хотя бы 3 из следующих методов: наивный Байесовский классификатор, метод ближайших соседей, случайный лес, градиентный бустинг и логистическая регрессия.

Ответ

В этом разделе прогнозируется бинарная переменная воздействия `premium_subscription`. Обозначим ее через

$$D_i \in \{0, 1\},$$

а вектор наблюдаемых признаков через

$$X_i = (\text{income}_i, \text{age}_i, \text{urban_area}_i, \text{family_size}_i, \text{free_trial_banner}_i).$$

Классификатор оценивает условную вероятность подписки

$$\hat{p}_i = \widehat{P}(D_i = 1 \mid X_i),$$

после чего бинарный прогноз при пороге c строится по правилу

$$\hat{D}_i(c) = \mathbb{1}\{\hat{p}_i \geq c\}.$$

Подключим библиотеки, которые используются для оценки классификаторов, подбора гиперпараметров, расчета метрик и построения графиков.

Импорты соответствуют методам и техникам, которые использовались в семинарах по классификации: `GridSearchCV` для подбора гиперпараметров, `cross_val_score` для кросс-валидации, `predict_proba` для получения вероятностей и ROC/AUC, а также `confusion_matrix` для подсчета TP, TN, FP, FN. Дополнительно подключаются модели пяти основных типов из задания.

Загрузим полную выборку и сохраненное разбиение на обучающую и тестовую части из раздела 2.

По первым строкам проверяем, что в данных есть зависимая переменная `monthly_spending`, переменная воздействия `premium_subscription` и наблюдаемые признаки для классификации. Важно, что для блока классификации мы прогнозируем именно воздействие `premium_subscription`, а не расходы клиента. Поэтому `monthly_spending` остается в данных для других разделов, но не используется как признак здесь.

Задание 3.1

Отберите признаки, которые могут быть полезны при прогнозировании переменной воздействия. Не включайте в число этих признаков целевую переменную.

Ответ

Отберем признаки, которые могут быть полезны для прогнозирования переменной воздействия. В классификационной задаче используется модель вида

$$D_i = f(X_i) + \varepsilon_i,$$

где D_i - факт оформления премиум-подписки, а X_i - набор наблюдаемых характеристик клиента. Целевая переменная `monthly_spending` не включается в признаки классификационных моделей, потому что в этом разделе прогнозируется именно переменная воздействия.

В качестве признаков используются доход, возраст, проживание в крупном городе, размер семьи и факт показа баннера. Ненаблюдаемая склонность к онлайн-покупкам не используется: это соответствует общему условию блока 3, согласно которому скрытые переменные, созданные для эндогенности, нельзя включать в модели.

Экономическая логика выбора признаков такая: доход отражает платежеспособность, возраст может быть связан с цифровыми привычками, городская среда и размер семьи влияют на ценность доставки, а баннер является наблюдаемым маркетинговым стимулом.

Сформируем обучающую и тестовую выборки из сохраненных файлов, чтобы во всех разделах проекта использовалось одно и то же разбиение.

Размеры обучающей и тестовой выборок

{'n_train': 22500, 'n_test': 7500}

Размер тестовой выборки составляет 25% от всех наблюдений, что соответствует требованию задания о тестовой доле от 20% до 30%. Мы используем сохраненные `df_train.csv` и `df_test.csv`, а не режем данные заново, чтобы классификация, регрессия и эффекты воздействия опирались на одно и то же разбиение.

Подготовим две версии признаков: исходную для деревьев и наивного Байеса, а также стандартизированную для логистической регрессии и KNN. Стандартизация каждого признака имеет вид

$$X_{ij}^{std} = \frac{X_{ij} - \bar{X}_{j,train}}{s_{j,train}},$$

где среднее и стандартное отклонение считаются только на обучающей выборке. Для KNN и логита стандартизация будет также встроена в Pipeline, чтобы кросс-валидация не использовала информацию из валидационных фолдов.

Деревянные модели получают исходные признаки, потому что разбиения в деревьях не зависят от масштаба переменных. Для KNN и логистической регрессии масштаб важен: KNN сравнивает расстояния между наблюдениями, а логистическая регрессия численно оптимизирует функцию потерь. Как в семинаре по KNN, стандартизация выполняется по train и затем применяется к test, чтобы не допустить утечки информации из тестовой выборки.

Задание 3.2

Для каждого метода:

- оцените точность (ассигасу), используя произвольные значения гиперпараметров на обучающей выборке, тестовой выборке и с помощью кросс-валидации;
- с помощью кросс-валидации на обучающей выборке подберите оптимальные значения гиперпараметров;
- в одной таблице укажите исходные и подобранные значения гиперпараметров, а также кросс-валидационную точность (ассигасу) и точность на тестовой выборке до и после тюнинга;
- обсудите наличие или отсутствие признаков переобучения модели;
- проинтерпретируйте полученные результаты.

Ответ

Для каждого из пяти классификаторов зададим исходные гиперпараметры и сетки для подбора. Качество сравнивается по ассигасу на train, test и кросс-валидации:

$$ACC = \frac{TP + TN}{TP + TN + FP + FN}.$$

Кросс-валидационная ассигасу считается как среднее качество по фолдам:

$$CV-ACC = \frac{1}{K} \sum_{k=1}^K ACC_k.$$

Переобучение проявляется, если качество на train заметно выше качества на test и на кросс-валидации.

Техническое примечание, как в семинарах: GridSearchCV перебирает все комбинации гиперпараметров из заданной сетки param_grid. Для каждой комбинации модель обучается на нескольких train-folds и проверяется на validation-folds. Затем выбирается комбинация с максимальным средним значением метрики scoring.

В этом блоке используются пять методов: наивный Байес, KNN, случайный лес, градиентный бустинг и логистическая регрессия. Для KNN и логита используется Pipeline, чтобы стандартизация выполнялась внутри каждого fold кросс-валидации.

Оценим исходные модели и затем подберем гиперпараметры по ассурасу с помощью кросс-валидации. Формально для каждой модели выбирается набор гиперпараметров

$$\hat{\lambda} = \arg \max_{\lambda \in \Lambda} CV-ACC(\lambda),$$

где Λ - заданная сетка перебираемых значений.

Сравнение пяти классификаторов до и после тюнинга по ассурасу

модель	исходные гиперпараметры	подобранные гиперпараметры	train-ACC до тюнинга	CV-ACC до тюнинга	CV-ACC после тюнинга	test-ACC до тюнинга	test-ACC после тюнинга	test-AUC после тюнинга	test-F1 после тюнинга
Градиентный бустинг	{'ccp_alpha': 0.0000, 'criterion': 'friedman_mse'...	{'learning_rate': 0.10, 'max_depth': 2, 'n_esti...	0.70	0.696	0.696	0.687	0.688	0.764	0.675
Случайный лес	{'bootstrap': True, 'ccp_alpha': 0.0000, 'class_w...	{'max_depth': 8, 'max_features': None, 'n_esti...	0.698	0.694	0.694	0.687	0.685	0.760	0.671
KNN	{'memory': None, 'steps': [('scaler', Standard...	{'model__n_neighbors': 75, 'model__weights': '...	1	0.669	0.693	0.674	0.685	0.758	0.672
Наивный Байес	{'priors': None, 'var_smoothing': 0.0000}	{'var_smoothing': 0.0000}	0.647	0.647	0.674	0.637	0.670	0.742	0.636
Логит	{'memory': None, 'steps': [('scaler', Standard...	{'model__C': 0.01, 'model__penalty': 'l2'}	0.670	0.669	0.669	0.665	0.665	0.729	0.657

Таблица показывает качество до и после тюнинга для всех пяти методов. Признаки переобучения оцениваются по разрыву между train accuracy и CV/test accuracy: чем больше train выигрывает у внешних оценок, тем сильнее модель запоминает обучающую выборку.

По результатам видно, что наиболее явный признак переобучения есть у исходного KNN: train-ACC = 1.000, тогда как CV-ACC = 0.669. Это типично для метода ближайших соседей с weights='distance': на обучающей выборке каждое наблюдение фактически очень хорошо узнается моделью. После тюнинга KNN test accuracy возрастает с 0.674 до 0.685, а CV ассурасу - до 0.693, поэтому переобучение становится менее проблемным.

Лучшее test-ACC после тюнинга среди базовых методов дает градиентный бустинг (0.688), за ним идут случайный лес (0.685) и KNN (0.685). Различия небольшие, значит по одной ассурасу нельзя делать слишком сильный вывод о доминировании одной модели. Логит показывает более стабильное, но более низкое качество (test-ACC = 0.665), что ожидаемо для линейной модели при наличии нелинейностей и взаимодействий. Наивный Байес улучшился после тюнинга (0.637 до 0.670), но все равно уступает более гибким алгоритмам, потому что его предпосылка условной независимости признаков слишком сильна для нашей DGP.

Сохраним отдельные имена для трех моделей, которые используются в следующих технических блоках и в сравнении с семинарскими примерами.

Эти объекты являются теми же tuned-моделями из общей таблицы, поэтому последующие расчеты остаются согласованными с анализом пяти классификаторов.

Повышенная сложность к заданию 3.2

Подберите на обучающей выборке оптимальные значения гиперпараметров случайного леса, ориентируясь на значение OOB (out-of-bag) ошибки. Сопоставьте гиперпараметры и точность на тестовой выборке для случайного леса в зависимости от того, используется кросс-валидация или OOB ошибка. Объясните преимущества и недостатки OOB ошибки по сравнению с кросс-валидацией.

Ответ

Для случайного леса дополнительно подберем гиперпараметры по OOB-ошибке и сравним этот выбор с подбором по кросс-валидации. Для наблюдения i OOB-прогноз строится только по тем деревьям, которые не использовали это наблюдение в своей bootstrap-выборке:

$$\hat{D}_i^{OOB} = \text{majority}\{\hat{D}_i^{(b)} : i \notin B_b\}.$$

OOB-ошибка считается как доля неправильных OOB-прогнозов:

$$OOB = \frac{1}{n} \sum_{i=1}^n \mathbb{1}\{\hat{D}_i^{OOB} \neq D_i\}.$$

Переберем ту же сетку гиперпараметров случайного леса, но критерием выбора будет минимальная OOB-ошибка.

Перебор гиперпараметров случайного леса по OOB-ошибке

модель	max_depth max_features	n_estimators	OOB error	test-ACC
0	12 None	120	0.306	0.684
1	12 sqrt	120	0.306	0.691
2	8 None	120	0.306	0.685
3	12 None	80	0.307	0.685
4	12 sqrt	80	0.307	0.689
5	8 sqrt	80	0.307	0.686
6	8 None	80	0.308	0.686
7	5 None	120	0.308	0.689
8	8 sqrt	120	0.308	0.688
9	5 sqrt	80	0.308	0.688
10	5 None	80	0.309	0.689
11	5 sqrt	120	0.309	0.686

В таблице меньшая OOB-ошибка означает более предпочтительную комбинацию гиперпараметров по внутренней оценке случайного леса. Как в семинаре по деревьям, `oob_score_` в `sklearn` отражает долю верных OOB-прогнозов, поэтому OOB-ошибка считается как $1 - \text{oob_score_}$.

Минимальная OOB-ошибка получилась у леса с большей глубиной (`max_depth=12`) и `n_estimators=120`. Это означает, что внутри bootstrap-процедуры более сложный лес лучше объясняет обучающие данные. Однако это еще не гарантирует максимальное качество на `test`.

Сравним случайный лес, выбранный по ассигасу на кросс-валидации, со случайным лесом, выбранным по OOB-ошибке.

Сравнение выбора случайного леса по CV и OOB

модель	подобранные гиперпараметры	OOB error	CV accuracy	test accuracy
RF tuned by CV	{ 'max_depth': 8, 'max_features': None, 'n_esti...	0.306	0.694	0.685
RF tuned by OOB	{ 'max_depth': 12, 'max_features': None, 'n_est...	0.306	0.693	0.684

Эта таблица показывает, совпадает ли выбор гиперпараметров по OOB с выбором по кросс-валидации. OOB удобна тем, что не требует отдельного разбиения на фолды: каждое дерево само оставляет часть наблюдений вне

bootstrap-выборки, и эти наблюдения используются для проверки.

В нашем случае OOB и CV выбирают разные варианты: CV выбирает `max_depth=8`, а OOB - `max_depth=12`. При этом `test accuracy` у CV-выбора (0.685) немного выше, чем у OOB-выбора (0.684). Разница мала, но она показывает главный недостаток OOB: это быстрая внутренняя оценка для ансамблей, однако она не всегда совпадает с кросс-валидацией и не применима к неансамблевым методам вроде логита или KNN без бэггинга.

Задание 3.3

Повторите предыдущий пункт, используя любой альтернативный критерий качества модели. Обоснуйте возможные преимущества и недостатки этого альтернативного критерия.

Ответ

Повторим тюнинг для всех пяти классификаторов, используя F1 вместо `accuracy`. Сначала определяются

$$Precision = \frac{TP}{TP + FP},$$

$$Recall = \frac{TP}{TP + FN}.$$

F1 является гармоническим средним `precision` и `recall`:

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}.$$

Этот критерий полезен, когда важно одновременно контролировать ложные срабатывания и пропуски положительного класса.

Тюнинг пяти классификаторов по F1

модель	исходные гиперпараметры	подобранные гиперпараметры (F1)	CV-F1 до тюнинга	CV-F1 после тюнинга	test-F1 до тюнинга	test-F1 после тюнинга
Случайный лес	{'bootstrap': True, 'ccp_alpha': 0.0000, 'class_w...	{'max_depth': 5, 'max_features': 'sqrt', 'n_es...	0.683	0.683	0.673	0.678
Градиентный бустинг	{'ccp_alpha': 0.0000, 'criterion': 'friedman_mse'...	{'learning_rate': 0.10, 'max_depth': 2, 'n_esti...	0.683	0.686	0.670	0.675
KNN	{'memory': None, 'steps': [('scaler', Standard...	{'model_n_neighbors': 75, 'model_weights': '...	0.662	0.683	0.666	0.672
Логит	{'memory': None, 'steps': [('scaler', Standard...	{'model_C': 0.10, 'model_penalty': 'l2'}	0.660	0.660	0.657	0.657
Наивный Байес	{'priors': None, 'var_smoothing': 0.0000}	{'var_smoothing': 0.0000}	0.574	0.642	0.560	0.636

Если порядок моделей по F1 отличается от порядка по `accuracy`, значит выбор критерия качества влияет на практическое решение. В этой задаче F1 особенно важен для оценки качества прогнозирования положительного класса `premium_subscription = 1`.

По F1 лучшим на тестовой выборке оказывается случайный лес (`test-F1 = 0.678`), немного опережая градиентный бустинг (0.675) и KNN (0.672). Это отличается от `accuracy/AUC`, где чаще лидирует градиентный бустинг. Причина в том, что F1 сильнее фокусируется на балансе `Precision` и `Recall` для класса 1, а не на общей доле правильных прогнозов.

Повышенная сложность к заданию 3.3

Дополнительно самостоятельно запрограммируйте не представленный в стандартных библиотеках критерий качества и используйте его для тюнинга гиперпараметров. Сравните результат стандартного и вашего критериев,

а также опишите его преимущества и недостатки: в каких случаях его разумно применять, а в каких случаях он может оказаться не очень полезен.

Ответ

Зададим нестандартный критерий качества, который не используется как готовая метрика из стандартных библиотек. В нашей задаче положительный класс означает, что клиент оформит премиум-подписку. Ошибка FN означает, что модель ошибочно считает такого клиента неподписчиком. В прикладной логике это особенно нежелательно: компания может отправить промокод клиенту, который и так бы подписался, и получить лишние издержки.

Поэтому зададим взвешенную полезность классификации:

$$CustomUtility = \frac{2TP + 1TN - 1FP - 3FN}{N},$$

где $N = TP + TN + FP + FN$. Здесь TP получает наибольший положительный вес, потому что модель верно находит подписчика; TN тоже полезен, но слабее; FP штрафруется умеренно; FN штрафруется сильнее всего, потому что пропуск положительного класса экономически наиболее неприятен в выбранной постановке.

Функция `custom_weighted_utility` вручную считает элементы confusion matrix и возвращает среднюю полезность на одно наблюдение. Внутри нее не используются готовые sklearn-метрики.

Повторим подбор гиперпараметров для всех пяти моделей, но теперь критерием оптимизации будет `CustomUtility`. Для сопоставимости рядом сохраним результаты стандартного F1-тюнинга.

Сравнение стандартного F1 и собственной custom metric

модель	лучшие параметры по F1	test-F1 после F1-тюнинга	custom utility на test после F1-тюнинга	лучшие параметры по custom utility	CV		test-ACC после custom utility	test-F1 после custom utility	test-AUC после custom utility
					custom utility	custom utility на test			
Градиентный бустинг	{'learning_rate': 0.10, 'max_depth': 2, 'n_estimators': 100}	0.675	0.358	{'learning_rate': 0.05, 'max_depth': 2, 'n_estimators': 100}	0.405	0.378	0.685	0.679	0.758
Случайный лес	{'max_depth': 5, 'max_features': 'sqrt', 'n_estimators': 100}	0.678	0.374	{'max_depth': 5, 'max_features': 'sqrt', 'n_estimators': 100}	0.393	0.374	0.686	0.678	0.760
KNN	{'model__n_neighbors': 75, 'model__weights': 'distance'}	0.672	0.348	{'model__n_neighbors': 75, 'model__weights': 'distance'}	0.391	0.348	0.685	0.672	0.758
Логит	{'model__C': 0.10, 'model__penalty': 'l2'}	0.657	0.302	{'model__C': 0.10, 'model__penalty': 'l2'}	0.316	0.302	0.665	0.657	0.729
Наивный Байес	{'var_smoothing': 0.00001}	0.636	0.216	{'var_smoothing': 0.00001}	0.238	0.216	0.670	0.636	0.742

Итоговая таблица показывает, меняется ли выбор гиперпараметров при переходе от стандартного F1 к экономически взвешенной полезности. Если лучшая модель или параметры меняются, это означает, что стандартная статистическая метрика и прикладной критерий качества предпочитают разные правила классификации.

В нашем случае custom metric выбирает градиентный бустинг: его custom utility на test = 0.378, тогда как у случайного леса 0.374. При этом по F1 лучшим был случайный лес. Такая перестановка естественна: F1 симметрично агрегирует precision и recall, а наша custom metric явно сильнее штрафует FN, поэтому предпочитает модель, лучше соответствующую экономическим весам ошибок.

Итог выбора модели по F1 и custom metric

Лучшая модель по F1: Случайный лес
Лучшая модель по custom utility: Градиентный бустинг
Совпадает ли лучшая модель: нет

Новая метрика измеряет не только статистическую точность, но и полезность ошибок с учетом экономической асимметрии. Ее разумно применять, когда бизнес заранее понимает, что разные ошибки имеют разную цену.

Например, если пропуск подписчика (FN) приводит к лишним расходам на промокод или потере корректного управленческого решения, его нужно штрафовать сильнее.

Недостаток custom metric состоит в том, что веса задаются исследователем. Если веса выбраны плохо или не обоснованы содержательно, модель будет оптимизироваться под искусственный критерий. Поэтому мы используем custom metric как повышенную сложность и сравниваем ее с F1, а не заменяем все остальные метрики одной численной оценкой.

Задание 3.4

Постройте ROC-кривые для ваших моделей с подобранными гиперпараметрами и сравните их по AUC на тестовой выборке. Обсудите преимущества и недостатки AUC в сравнении с ACC в контексте вашей содержательной задачи.

Ответ

Построим ROC-кривые для пяти моделей с гиперпараметрами, подобранными по ассигасу. При каждом пороге c считаются

$$TPR(c) = \frac{TP(c)}{TP(c) + FN(c)},$$


$$FPR(c) = \frac{FP(c)}{FP(c) + TN(c)}.$$

ROC-кривая строит зависимость $TPR(c)$ от $FPR(c)$ при изменении порога. AUC равна площади под ROC-кривой:

$$AUC = \int_0^1 TPR(FPR) dFPR.$$

AUC сравнивает качество ранжирования вероятностей и не фиксирует заранее порог классификации.

ROC-кривые и AUC пяти классификаторов



модель	AUC
Градиентный бустинг	0.764
Случайный лес	0.760
KNN	0.758
Наивный Байес	0.742
Логит	0.729

Чем выше ROC-кривая и чем больше AUC, тем лучше модель отделяет клиентов с подпиской от клиентов без подписки при разных порогах. В отличие от ассурасу, AUC оценивает не одно бинарное решение, а качество ранжирования вероятностей.

По AUC на тестовой выборке лучший результат у градиентного бустинга (0.764), далее идут случайный лес (0.760) и KNN (0.758). Наивный Байес (0.742) и логит (0.729) уступают. Это согласуется с содержательной DGP: в данных есть нелинейные зависимости и взаимодействия, которые ансамбли деревьев ловят лучше, чем линейная логистическая регрессия и наивный Байес с сильной предпосылкой условной независимости.

Сохраним AUC для трех базовых моделей, чтобы итоговые таблицы и дальнейшие блоки могли обращаться к тем же значениям.

Повторный вывод таблицы фиксирует общий порядок пяти моделей по AUC на тестовой выборке. В дальнейших итоговых сравнениях именно AUC используется как основной критерий выбора лучшего и худшего классификатора, потому что в прикладной задаче порог затем подбирается отдельно по прибыли.

Задание 3.5

Для любой модели на ваш выбор постройте матрицу ошибок на тестовой выборке при стандартном пороге классификации 0.50. Обсудите, какие ошибки встречаются чаще и с чем это может быть связано.

Ответ

Для каждой модели построим матрицу ошибок при стандартном пороге классификации $c = 0.50$:

$$\hat{D}_i = \mathbb{1}\{\hat{p}_i \geq 0.50\}.$$

Матрица ошибок имеет вид

	$\hat{D} = 0$	$\hat{D} = 1$
$D = 0$	TN	FP
$D = 1$	FN	TP

и показывает, какие типы ошибок делает модель.

Матрицы ошибок при стандартном пороге 0.50

модель	TN	FP	FN	TP
Наивный Байес	2861	924	1550	2165
KNN	2710	1075	1291	2424
Случайный лес	2737	1048	1312	2403
Градиентный бустинг	2729	1056	1283	2432
Логит	2588	1197	1312	2403

Матрица ошибок показывает, какие ошибки встречаются чаще: ложные срабатывания FP или пропуски подписчиков FN. Для бизнес-задачи это важно, потому что разные ошибки могут иметь разную стоимость.

При пороге 0.50 у всех моделей число FP и FN достаточно велико, что ожидаемо при умеренной предсказательной силе признаков. Например, градиентный бустинг дает TP=2432, TN=2729, FP=1056, FN=1283. Это означает, что модель лучше случайного угадывания, но все еще часто путает клиентов около границы решения. Поэтому дальнейший подбор порога по бизнес-метрике действительно нужен: стандартный порог 0.50 не обязан быть оптимальным для прибыли.

Задание 3.6

Для модели из предыдущего пункта рассмотрите не менее двух порогов, отличных от 0.50, и рассчитайте для каждого из них ACC, Precision и Recall. Результаты представьте в форме таблицы. Обсудите, как изменение порога прогнозирования влияет на распределение ошибок прогнозов различного типа. Уточните, какие из ошибок могут быть более существенными исходя из контекста вашей экономической задачи. Содержательно обоснуйте, какой из двух рассмотренных порогов может быть предпочтительнее.

Ответ

В задании требуется рассмотреть модель из предыдущего пункта. В пункте 3.5 матрицы ошибок были построены для всех моделей, поэтому для аккуратного сопоставления ниже приводятся пороги для всех пяти классификаторов. Это не меняет требование задания: для каждой модели, включая выбранный в предыдущем пункте градиентный бустинг, рассматриваются два порога, отличных от 0.50, а именно 0.30 и 0.70. Дополнительно оставлен стандартный порог 0.50 как база для сравнения.

При каждом пороге прогноз определяется правилом

$$\hat{D}_i(c) = \mathbb{1}\{\hat{p}_i \geq c\}.$$

Изменение c меняет соотношение между precision и recall: более низкий порог делает модель менее строгой, а более высокий порог - более строгой.

Качество моделей при разных порогах классификации

модель	модель	threshold	ACC	Precision	Recall
0	Наивный Байес	0.30	0.623	0.575	0.917
1	Наивный Байес	0.50	0.670	0.701	0.583
2	Наивный Байес	0.70	0.593	0.795	0.240
3	KNN	0.30	0.635	0.585	0.908
4	KNN	0.50	0.685	0.693	0.652
5	KNN	0.70	0.637	0.807	0.353
6	Случайный лес	0.30	0.628	0.577	0.931
7	Случайный лес	0.50	0.685	0.696	0.647
8	Случайный лес	0.70	0.624	0.830	0.302
9	Градиентный бустинг	0.30	0.637	0.585	0.919
10	Градиентный бустинг	0.50	0.688	0.697	0.655
11	Градиентный бустинг	0.70	0.627	0.828	0.312
12	Логит	0.30	0.600	0.558	0.918
13	Логит	0.50	0.665	0.667	0.647
14	Логит	0.70	0.607	0.804	0.273

При снижении порога модель чаще прогнозирует подписку, поэтому recall обычно растет, а precision может снижаться. При повышении порога прогноз становится осторожнее: precision растет, но часть настоящих подписчиков чаще попадает в пропуски.

В таблице это видно для всех моделей: при пороге 0.30 recall примерно около 0.91–0.93, то есть модель находит почти всех подписчиков, но precision ниже. При пороге 0.70 precision возрастает примерно до 0.80–0.83, но recall падает до 0.24–0.35.

Если задача состоит в том, чтобы найти как можно больше клиентов, которые действительно оформят подписку самостоятельно, предпочтительнее низкий порог 0.30, потому что он уменьшает число пропущенных подписчиков (FN). Если важнее не ошибаться в положительных прогнозах, предпочтительнее высокий порог 0.70, потому что он уменьшает число ложноположительных прогнозов (FP). В нашей экономической постановке особенно существенны FN: такой клиент фактически склонен к подписке, но модель относит его к неподписчикам, и в следующей бизнес-логике ему могут зря отправить промокод. Поэтому из двух нестандартных порогов более осторожным для бюджета является 0.70, а для общей статистической точности компромиссным вариантом остается стандартный порог 0.50, потому что при нем ассигасу обычно выше, чем при крайних порогах.

Задание 3.7

Обсудите прикладную задачу, для решения которой может использоваться ваша классификационная модель. Опишите конкретного экономического агента (заказчика), который может быть заинтересован в использовании ваших прогнозов. Укажите, какие действия целесообразно предпринимать заказчику в зависимости от того, является ваш прогноз положительным или отрицательным. Исходя из этих действий и содержательных соображений предположите цены различных видов прогнозов. Руководствуясь критерием максимизации прибыли на обучающей выборке, подберите оптимальный порог прогнозирования для каждого из методов и сравните прибыли на тестовой выборке при соответствующих порогах. Результат представьте в форме таблицы, в которой должны быть указаны прибыли на тестовой выборке. Проинтерпретируйте полученный результат, в частности, объяснив, как выбранное на данных оптимальное значение порога соотносится с экономической интуицией.

Ответ

Рассмотрим прикладную задачу: сервис доставки использует прогноз, чтобы решать, кому отправлять промокод на бесплатный пробный период премиум-подписки. Важно зафиксировать направление управленческого действия. Положительный класс в классификации означает `premium_subscription = 1`, то есть клиент с высокой вероятностью оформит подписку сам. Поэтому воздействовать промокодом логичнее не на положительный прогноз, а на отрицательный: действие применяется к клиентам, для которых модель прогнозирует отсутствие подписки.

Для заданного порога c прибыль модели записывается как

$$Profit(c) = p_{TP}TP(c) + p_{TN}TN(c) + p_{FP}FP(c) + p_{FN}FN(c),$$

где $p_{TP}, p_{TN}, p_{FP}, p_{FN}$ - цены соответствующих исходов. Оптимальный порог выбирается на обучающей выборке:

$$c^* = \arg \max_c Profit_{train}(c).$$

Зададим цены исходов относительно сценария, в котором компания ничего не делает.

Цены ошибок и верных прогнозов для линейной прибыли

TP 0 TN 100 FP 0 FN -500 dtype: int64

Положительная прибыль у TN означает полезное действие для клиента, который без промокода не оформил бы подписку: модель верно относит его к классу 0, и компания может попытаться подтолкнуть его промокодом. Отрицательная прибыль у FN отражает лишнюю стоимость промокода для клиента, который на самом деле относится к классу 1 и с высокой вероятностью подписался бы сам.

Важно, что здесь экономическая интерпретация отличается от стандартного правила “класс 1 = воздействовать”. В нашей постановке класс 1 - это прогноз самостоятельной подписки, а промокод отправляется тем, для кого прогноз равен 0. Поэтому TN - это удачно найденный клиент без подписки, которому можно предложить промокод, а FN - подписчик, которому промокод был отправлен зря. Такая запись не противоречит confusion matrix: меняется не определение TP/TN/FP/FN, а бизнес-действие, которое компания привязывает к отрицательному прогнозу.

Запрограммируем функцию прибыли для произвольной модели и набора порогов.

Функция переводит вероятности в бинарные прогнозы при каждом пороге, считает типы ошибок и умножает их на заданные цены. Это повторяет семинарскую логику расчета прибыли: сначала строится прогноз при конкретном threshold, затем через confusion matrix получаются TP, TN, FP, FN, после чего считается сумма цен прогнозов.

Теперь выберем порог, максимизирующий прибыль на обучающей выборке, и перенесем его на тестовую выборку. В коде перебираются уникальные значения оцененных вероятностей на train:

$$c \in \{\hat{p}_i : i \in train\}.$$

Для каждого такого c считается $Profit_{train}(c)$, после чего выбранный c^* применяется к test.

Такой порядок нужен, чтобы не подбирать порог по тестовой выборке. Test используется только для финальной проверки прибыли.

В семинаре подчеркивалось, что порог c не обязан равняться 0.50: он должен отражать цены ошибок и верных прогнозов. Поэтому мы сначала выбираем c^* на train, а затем оцениваем, насколько выбранное правило переносится на test.

Рассчитаем оптимальные пороги и тестовую прибыль для всех пяти классификаторов.

Оптимальный порог и линейная прибыль на test

модель	оптимальный порог	прибыль на тесте
Случайный лес	0.189	22500
KNN	0.173	18000
Градиентный бустинг	0.165	17700
Наивный Байес	0.169	15300
Логит	0.164	6400

Модель с наибольшей тестовой прибылью лучше подходит именно для этой прикладной задачи. Оптимальный порог может быть ниже или выше 0.50, потому что он отражает не статистическую симметрию ошибок, а заданные экономические цены.

В полученной таблице оптимальные пороги для моделей находятся примерно в диапазоне 0.16-0.19, то есть заметно ниже стандартного порога 0.50. Это согласуется с экономической постановкой: промокод отправляется тем, кому модель прогнозирует отсутствие подписки. Низкий порог означает, что модель относит к классу 0 только клиентов с достаточно малой оцененной вероятностью подписки. Так компания избегает лишних промокодов для клиентов, которые с высокой вероятностью подписались бы сами.

По тестовой прибыли лучшим оказывается случайный лес (22500). Значит, хотя по AUC выше градиентный бустинг, при заданных ценах ошибок и оптимальном пороге именно случайный лес дает более выгодное управленческое правило. Это важный вывод: лучшая модель по статистической метрике и лучшая модель по прибыли могут различаться.

Повышенная сложность к заданию 3.7

Предложите, содержательно обоснуйте и примените собственную, отличную от линейной функцию прибыли от прогнозов.

Ответ

Базовая функция прибыли линейно суммирует выгоды и издержки отдельных прогнозов. Добавим более реалистичную бизнес-логику: если промокод отправляется слишком большому числу клиентов, возникают дополнительные организационные издержки, нагрузка на маркетинговый бюджет и риск обесценивания акции.

В этой постановке промокод отправляется клиентам с прогнозом $\hat{D}_i = 0$, потому что именно они считаются неподписчиками без дополнительного стимула. Поэтому число клиентов, на которых направлено воздействие, равно

$$Target(c) = TN(c) + FN(c).$$

Нелинейная прибыль задается как

$$Profit_{nonlinear}(c) = 100TN(c) - 500FN(c) - \gamma \cdot Target(c)^2.$$

Выберем $\gamma = 0.0020$. Такой штраф почти не влияет при малом числе промокодов, но быстро растет при массовой рассылке. Это отражает идею ограниченного маркетингового бюджета: компания хочет помогать клиентам, которые без промокода не подписались бы, но не хочет делать слишком широкую и дорогую акцию.

Функции вручную считают элементы confusion matrix и добавляют квадратичный штраф за масштаб воздействия. Готовые метрики качества для расчета прибыли здесь не используются.

Для каждой модели подберем порог по новой нелинейной прибыли на train. Затем сравним его с порогом, найденным в базовой линейной постановке.

Сравнение линейной и нелинейной функции прибыли

модель	threshold linear profit	threshold nonlinear profit	train nonlinear profit при linear threshold	test nonlinear profit при linear threshold	train nonlinear profit	test nonlinear profit	positive predictions test	targeted clients test	TP	FP	FN	TN
Случайный лес	0.189	0.19	75669.40	21829.50	74344.80	21522.60	6918	582	36553263	60	522	
Градиентный бустинг	0.165	0.17	65760.80	17148.80	63472.30	19959.30	6934	566	36553279	60	506	
KNN	0.173	0.17	68195	17562	68195	17562	7032	468	36673365	48	420	
Наивный Байес	0.169	0.17	39367.80	15018.80	38520	15215.70	7123	377	36783445	37	340	
Логит	0.164	0.17	19281.30	6256.35	17973.90	5015.17	7196	304	36733523	42	262	

Таблица показывает, как меняется стратегия после добавления нелинейного штрафа. В отличие от линейной прибыли, новая функция отдельно учитывает масштаб промоакции через `targeted clients test`: если порог приводит к слишком широкой рассылке, квадратичный штраф снижает итоговую прибыль.

У случайного леса линейный и нелинейный пороги почти совпадают (0.189 и 0.19), поэтому стратегия устойчива к добавлению штрафа. У градиентного бустинга порог также остается близким (0.165 и 0.17). При этом по нелинейной прибыли случайный лес снова оказывается лучшим (21522.55). Это означает, что он лучше балансирует между выгодой от таргетирования и затратами на слишком широкое воздействие.

Лучшая модель по нелинейной прибыли

Лучшая модель по нелинейной прибыли: Случайный лес. Оптимальный threshold для лучшей модели: 0.19. Максимальная test nonlinear profit: 21522.55.

По нелинейной прибыли лучшей считается модель с максимальным test nonlinear profit. Если оптимальный нелинейный порог отличается от линейного, это означает, что учет ограниченного маркетингового бюджета меняет управленческую стратегию: модель выбирает не просто максимум ожидаемой выгоды по отдельным клиентам, а баланс между выгодой и масштабом воздействия.

В нашем случае нелинейная прибыль не переворачивает общий бизнес-вывод: лучшим остается случайный лес. Но сама таблица становится богаче: она показывает не только прибыль, но и число клиентов, на которых направляется воздействие (`targeted clients test`), а также TP, FP, FN, TN. Это делает решение более интерпретируемым для заказчика.

Задание 3.8

Опишите предполагаемые связи между переменными в форме ориентированного ациклического графа (DAG). Обучите структуру Байесовской сети на обучающей выборке и сравните точность прогнозов вашего и обученного DAG на тестовой выборке.

Ответ

Зададим содержательный DAG между наблюдаемыми признаками и переменной `premium_subscription`, затем сравним его прогнозы с DAG, структура которого обучена по данным.

В Байесовской сети совместное распределение переменных раскладывается по графу:


$$P(V_1, \dots, V_m) = \prod_{j=1}^m P(V_j \mid Pa(V_j)),$$

где $Pa(V_j)$ - родители узла V_j в DAG. Для прогноза подписки используется условное распределение

$$P(D_i = 1 \mid X_i).$$

Сначала построим пользовательский DAG на основе экономической логики задачи.

Пользовательский DAG Байесовской сети



На графе признаки влияют на вероятность подписки, а также на вероятность показа баннера. Это соответствует содержательной истории таргетированной маркетинговой акции.

DAG полезен тем, что явно фиксирует предположения о направлении связей. В отличие от случайного леса или бустинга, Байесовская сеть не просто строит черный ящик для прогноза, а задает факторизацию совместного распределения через родительские узлы. Поэтому ее легче интерпретировать, хотя она может уступать гибким ансамблям по качеству прогноза.

Для дискретной Байесовской сети разобьем непрерывные признаки на интервалы. Вместо исходных `income` и `age` используются дискретные переменные

$$income_bin_i \in \{0, 1, 2\}, \quad age_bin_i \in \{0, 1, 2\}.$$

Границы бинов оцениваются только на `train` и затем применяются к `test`.

Такой биннинг не использует тестовую выборку при выборе границ, поэтому прогноз Байесовской сети проверяется на честном `test`.

Биннинг нужен потому, что используемая дискретная Байесовская сеть оценивает таблицы условных вероятностей для конечного числа состояний. Для `income` и `age` строятся три группы, а бинарные/дискретные признаки уже имеют конечное число значений.

Оценим параметры пользовательского DAG на обучающей выборке. При фиксированной структуре графа оцениваются условные вероятности вида

$$\widehat{P}(V_j = v \mid Pa(V_j) = pa),$$

то есть таблицы условных вероятностей для каждого узла.

В этом блоке структура задана вручную, а условные вероятности в узлах оцениваются по обучающим данным. Иными словами, мы фиксируем экономическую структуру DAG, а затем по `train` оцениваем таблицы вида $P(V_j \mid$

$Pa(V_j)$). Это отделяет содержательную часть модели от статистической оценки параметров.

Получим прогноз пользовательского DAG на тестовой выборке.

Полученная ассигасу показывает, насколько хорошо содержательно заданный DAG прогнозирует подписку на тестовой выборке. Пользовательский DAG дает ассигасу около 0.677, что сопоставимо с более простыми классификаторами, но ниже лучших ансамблей деревьев. Это нормальный результат: ручная структура более интерпретируема, но менее гибка.

Теперь обучим структуру DAG автоматически на train.

Автоматически обученная структура отражает зависимости, которые алгоритм находит в данных по выбранному критерию качества структуры. В отличие от пользовательского DAG, здесь направления и наличие ребер выбираются алгоритмом, поэтому результат может лучше подстроиться под данные, но стать менее прозрачным содержательно.

Сравним точность пользовательского и обученного DAG на одной и той же тестовой выборке.

Сравнение показывает, дает ли автоматическое обучение структуры выигрыш относительно содержательного DAG. В текущих результатах ассигасу пользовательского DAG и обученного DAG почти совпадают: около 0.677. Это означает, что ручная структура уже хорошо отражает основные зависимости в данных, а автоматическое обучение структуры не дает заметного прироста качества по ассигасу.

В базовом пункте задания требуется сравнить точность прогнозов пользовательского и обученного DAG на тестовой выборке, поэтому здесь Байесовские сети сопоставляются именно по ACC test. Дальше в повышенной сложности мы дополнительно сравниваем их по ROC/AUC, то есть по качеству ранжирования вероятностей.

Повышенная сложность к заданию 3.8

Постройте ROC-кривую для Байесовской сети и сравните ее AUC с теми, что были получены для иных методов.

Ответ


Для ROC-кривой нужны не только бинарные классы 0/1, а оцененные вероятности положительного класса:

$$\widehat{P}(D_i = 1 \mid X_i).$$

`bnlearn.predict` возвращает предсказанный класс и вероятность этого предсказанного класса. Поэтому вероятность положительного класса восстанавливается так: если Байесовская сеть предсказала 1, берем p ; если предсказала 0, берем $1-p$. Это дает сопоставимый с другими моделями скоринг для построения ROC и расчета AUC.

Теперь построим ROC-кривые для пользовательского и обученного DAG на тестовой выборке.

ROC-кривая и AUC Байесовской сети



модель	AUC
Байесовская сеть: пользовательский DAG	0.736
Байесовская сеть: обученный DAG	0.740

Для сравнения добавим Байесовскую сеть в общую таблицу AUC вместе с пятью классификаторами из предыдущих пунктов.

Сравнение AUC Байесовской сети с другими классификаторами

модель	AUC
Градиентный бустинг	0.764
Случайный лес	0.760
KNN	0.758
Наивный Байес	0.742
Байесовская сеть: обученный DAG	0.740
Байесовская сеть: пользовательский DAG	0.736
Логит	0.729

Таблица сравнивает качество ранжирования по вероятностям. Если AUC Байесовской сети ниже AUC лучших ансамблевых моделей, это означает, что сеть хуже ранжирует клиентов по вероятности подписки.

В нашем случае обученный DAG имеет AUC около 0.741, пользовательский DAG - около 0.736. Это немного ниже градиентного бустинга (0.764), случайного леса (0.760) и KNN (0.758), но выше логистической регрессии

(0.729). Возможная причина результата: Байесовская сеть более интерпретируема и явно опирается на структуру зависимостей, тогда как случайный лес и градиентный бустинг лучше ловят сложные нелинейные пороги и взаимодействия между признаками.

Сравнение лучшей базовой модели и Байесовской сети по AUC

Лучшая базовая модель по AUC: Градиентный бустинг 0.764 Лучшая Байесовская сеть по AUC: Байесовская сеть: обученный DAG 0.740 Разница AUC лучшей базовой модели и лучшей BN: 0.024

ROC/AUC показывает именно качество ранжирования вероятностей, а не качество одного фиксированного порога. Поэтому Байесовская сеть может иметь ассигасу, близкую к другим моделям при пороге/правиле классификации, но уступать по AUC, если ее вероятности хуже упорядочивают клиентов от менее склонных к подписке к более склонным.

Содержательно это означает, что BN можно использовать как интерпретируемую вероятностную модель, но если главная цель - максимально точное ранжирование клиентов для последующего выбора порога, то ансамблевые методы остаются предпочтительнее.

Задание 3.9

На основании проделанного анализа выберите лучший и худший из обученных классификаторов. Обсудите полученный результат.

Примечание: необходимо самостоятельно сформулировать разумный критерий, в соответствии с которым будут определяться лучшая и худшая модели.

Ответ

Выберем лучший и худший классификатор по AUC на тестовой выборке. Критерий выбора:

$$m_{best} = \arg \max_m AUC_m,$$

$$m_{worst} = \arg \min_m AUC_m.$$

Этот критерий подходит здесь, потому что дальше порог можно выбирать отдельно под экономическую задачу.

Итоговая таблица качества пяти классификаторов

модель	test-ACC	AUC	CV-ACC
Градиентный бустинг	0.688	0.764	0.696
Случайный лес	0.685	0.760	0.694
KNN	0.685	0.758	0.693
Наивный Байес	0.670	0.742	0.674
Логит	0.665	0.729	0.669

Итоговая таблица объединяет test accuracy, AUC и CV accuracy для моделей после тюнинга по ассигасу.

Лучшие и худшие классификаторы по AUC

Три лучших классификатора по AUC: test-ACC AUC CV-ACC модель

Градиентный бустинг 0.688 0.764 0.696 Случайный лес 0.685 0.760 0.694 KNN 0.685 0.758 0.693

Лучшая модель: Градиентный бустинг Худшая модель: Логит

Лучшая модель имеет максимальный AUC на тестовой выборке, то есть лучше всего ранжирует клиентов по вероятности подписки. Худшая модель имеет минимальный AUC среди рассмотренных классификаторов.

По итоговой таблице лучший классификатор из методов курса - градиентный бустинг (AUC = 0.764), худший - логистическая регрессия (AUC = 0.729). Разница объясняется тем, что градиентный бустинг строит последовательный ансамбль деревьев и способен ловить нелинейности, а логит задает линейную зависимость логарифма шансов от признаков. При этом по бизнес-прибыли лучший метод может отличаться от лучшего по AUC, поэтому итоговый выбор модели зависит от цели: ранжирование вероятностей или максимизация прибыли.

Задание 3.10. Повышенная сложность

Включите в анализ дополнительный метод классификации, не рассматривавшийся в курсе и не представленный в библиотеке `scikit-learn`. Опишите данный метод (принцип работы, преимущества и недостатки) и осуществите тюнинг гиперпараметров. Сопоставьте его точность на тестовой выборке с точностью лучшего из обученных вами ранее методов. Добавление обычной регуляризации к классическим методам не считается отдельным методом.

Ответ

Добавим дополнительный метод классификации, который не рассматривался в курсе и не является моделью из `scikit-learn`: `CatBoostClassifier` из библиотеки `catboost`.

CatBoost - это градиентный бустинг над решающими деревьями. Его важные особенности: ordered boosting, снижающий смещение при обучении, и удобная работа с категориальными признаками без ручного one-hot encoding. В этой задаче категориальными считаем `urban_area`, `family_size` и `free_trial_banner`; непрерывные `income` и `age` передаются как числовые признаки.

Преимущества CatBoost: он хорошо ловит нелинейности и взаимодействия признаков, часто дает сильное качество без сложной предобработки категорий. Недостатки: модель менее интерпретируема, имеет больше гиперпараметров и может переобучаться при слишком большой глубине или числе итераций.

Зададим компактную сетку гиперпараметров, чтобы тюнинг был воспроизводимым и не слишком тяжелым. Как и в семинарском `GridSearchCV`, перебираются заранее заданные комбинации параметров. Для CatBoost важны число итераций бустинга, глубина деревьев, скорость обучения и L2-регуляризация листьев.

Подберем гиперпараметры CatBoost по ассигасу на кросс-валидации, чтобы сравнение было согласовано с основной таблицей моделей. Категориальные признаки передаются через `cat_features`, поэтому CatBoost сам строит внутренние кодировки категорий и не требует ручного one-hot encoding.

Итоговое качество CatBoostClassifier

модель лучшие гиперпараметры	train-ACC	CV-ACC	test-ACC	test-F1	test-AUC	test custom utility	linear profit threshold	test linear profit	nonlinear profit threshold	test nonlinear profit
CatBoost{'depth': 4, 'iterations': 300, 'l2_leaf_reg': ...}	0.704	0.698	0.686	0.670	0.763	0.340	0.174	21600	0.15	23087.90

Сравним CatBoost с лучшей моделью из методов курса по test-метрикам. В качестве базовой лучшей модели берем классификатор с максимальным AUC из пункта 3.9 - градиентный бустинг. Это честное сравнение дополнительного внешнего метода с лучшим методом, который уже был обучен в основной части блока.

Сравнение CatBoost с лучшей моделью из методов курса

модель	test-ACC	test-F1	test-AUC	test custom utility	test linear profit	test nonlinear profit
Градиентный бустинг	0.688	0.675	0.764	0.358	17700	19959.30
CatBoost	0.686	0.670	0.763	0.340	21600	23087.90

Добавим CatBoost в общую таблицу AUC базовых классификаторов, чтобы увидеть его место относительно моделей из курса. AUC здесь особенно удобен: он сравнивает не один выбранный порог, а общее качество вероятностного ранжирования клиентов.

Место CatBoost в общей таблице AUC

модель	AUC
Градиентный бустинг	0.764
CatBoost	0.763
Случайный лес	0.760
KNN	0.758
Наивный Байес	0.742
Логит	0.729

Итог сравнения CatBoost с методами курса

Лучшая модель из методов курса: Градиентный бустинг Лучшая модель после добавления CatBoost: Градиентный бустинг Разница AUC CatBoost и лучшей модели курса: -0.0007

CatBoost почти догоняет лучшую модель из курса по AUC, но не улучшает ее: у градиентного бустинга AUC = 0.764, у CatBoost AUC = 0.763, разница около -0.0007. Это практически паритет по качеству ранжирования, но формально лучшей моделью по AUC остается градиентный бустинг.

При этом CatBoost дает более высокую нелинейную прибыль в сравнительной таблице (23087.93 против 19959.29 у градиентного бустинга). Поэтому CatBoost полезен как сильный внешний benchmark: по статистическому AUC он не превосходит лучший метод курса, но по бизнес-критерию с нелинейным штрафом может быть предпочтительнее. Итоговый выбор зависит от приоритета: если нужен простой и уже изученный метод с лучшим AUC, выбираем градиентный бустинг; если важнее бизнес-прибыль по нашей нелинейной функции, CatBoost выглядит привлекательнее, хотя он менее интерпретируем и требует внешней библиотеки.

Задание 3.11

В случае необходимости проведите дополнительный анализ.

Ответ

Проведем дополнительные проверки, которые помогают интерпретировать качество классификаторов и убедиться, что результаты не сводятся к простому дисбалансу классов или одному признаку.

Доля единиц в выборке считается как

$$\bar{D} = \frac{1}{n} \sum_{i=1}^n D_i.$$

Попарное совпадение прогнозов двух моделей a и b считается как

$$Agreement(a, b) = \frac{1}{n} \sum_{i=1}^n \mathbb{1}\{\hat{D}_i^a = \hat{D}_i^b\}.$$

Сначала посмотрим долю единиц в train и test.

Проверка долей классов в train и test

модель	metric	value
0	train_share_ones	0.494
1	test_share_ones	0.495

Близкие доли единиц в train и test означают, что разбиение не создало заметного сдвига по целевой переменной. В обеих выборках доля подписчиков близка к 0.49–0.50, поэтому различия в качестве моделей нельзя объяснить тем, что в test случайно попал совсем другой баланс классов.

Сравним бинарные прогнозы моделей попарно.

Совпадение бинарных прогнозов между моделями

модель models	share_equal
8 Случайный лес vs Логит	0.846
6 KNN vs Логит	0.851
9 Градиентный бустинг vs Логит	0.853
0 Наивный Байес vs KNN	0.858
1 Наивный Байес vs Случайный лес	0.863
2 Наивный Байес vs Градиентный бустинг	0.868
3 Наивный Байес vs Логит	0.882
4 KNN vs Случайный лес	0.927
5 KNN vs Градиентный бустинг	0.932
7 Случайный лес vs Градиентный бустинг	0.933

Если доля совпадающих прогнозов очень высока, модели фактически принимают похожие решения. Если совпадение ниже, разные алгоритмы по-разному используют структуру признаков.

В нашем случае совпадение прогнозов между некоторыми моделями находится около 0.85–0.86, а между KNN, случайным лесом и градиентным бустингом выше 0.93. Это означает, что сильные нелинейные модели часто классифицируют клиентов похожим образом, но логит и наивный Байес принимают более отличающиеся решения.

Сравним предсказанные вероятности моделей. Для двух моделей a и b считается корреляция между векторами вероятностей:

$$\text{Corr}(\hat{p}^a, \hat{p}^b) = \text{Corr}((\hat{p}_1^a, \dots, \hat{p}_n^a), (\hat{p}_1^b, \dots, \hat{p}_n^b)).$$

Эта проверка показывает, насколько похоже модели ранжируют клиентов.

Корреляция предсказанных вероятностей между моделями

модель models	corr
6 KNN vs Логит	0.855
8 Случайный лес vs Логит	0.856
0 Наивный Байес vs KNN	0.860
9 Градиентный бустинг vs Логит	0.863
1 Наивный Байес vs Случайный лес	0.875
2 Наивный Байес vs Градиентный бустинг	0.879
3 Наивный Байес vs Логит	0.892
4 KNN vs Случайный лес	0.959
5 KNN vs Градиентный бустинг	0.962
7 Случайный лес vs Градиентный бустинг	0.979

Корреляция вероятностей показывает, насколько похоже модели ранжируют клиентов, даже если бинарные прогнозы при пороге 0.50 частично совпадают.

Высокая корреляция вероятностей между случайным лесом и градиентным бустингом означает, что эти модели не только часто дают одинаковые классы, но и похожим образом упорядочивают клиентов по вероятности подписки. Более низкая корреляция с логитом показывает, что линейная модель видит структуру риска иначе.

Для случайного леса и градиентного бустинга посмотрим важность признаков.

Важность признаков в случайном лесу и градиентном бустинге

модель	rf_importance	gb_importance
income	0.447	0.225
age	0.303	0.243
family_size	0.119	0.185
urban_area	0.077	0.195
free_trial_banner	0.055	0.152

Важности признаков показывают, какие переменные деревья чаще используют для разделения клиентов. Это помогает понять, не доминирует ли один признак над всей классификацией.

У случайного леса наибольшие важности получают `income` и `age`, у градиентного бустинга вклад распределен более равномерно между `income`, `age`, `urban_area`, `family_size` и `free_trial_banner`. Это хорошо: модель не сводится только к инструменту `free_trial_banner`, а использует несколько экономически осмысленных характеристик клиента.

Проверим качество простого правила, которое использует только `free_trial_banner`:

$$\hat{D}_i^{banner} = free_trial_banner_i.$$

Это базовое сравнение показывает, насколько далеко можно продвинуться без обучения сложной модели.

Качество простого правила по баннеру

модель	metric	value
0	ACC_banner_only	0.609
1	Precision_banner_only	0.654
2	Recall_banner_only	0.445

Если лучшее качество моделей заметно выше качества простого правила по баннеру, значит классификаторы используют не только инструмент, но и остальные признаки.

Простое правило по `free_trial_banner` дает $ACC = 0.609$, тогда как лучшая модель имеет $ACC = 0.688$. Разрыв около 0.079 показывает, что модели действительно извлекают дополнительную информацию из дохода, возраста, города и размера семьи. Это важная диагностическая проверка: классификация не должна превращаться в механическое повторение инструмента.

Соберем итоговую диагностическую таблицу по лучшей модели и простому правилу.

Итоговая диагностическая проверка классификации

модель	metric	value
0	ACC_banner_only	0.609
1	ACC_best_model	0.688
2	AUC_best_model	0.764
3	ACC_gap_best_minus_banner	0.079
4	min_pairwise_agreement	0.846
5	max_pairwise_agreement	0.933

Эта таблица резюмирует, насколько лучшая модель превосходит простое правило и насколько похожи между собой прогнозы разных классификаторов.

Итоговая диагностика поддерживает основной вывод блока: данные не являются тривиально предсказуемыми одним баннером, модели различаются между собой, а лучший классификатор дает заметный, но не огромный прирост качества. Поэтому дальнейший анализ эффектов воздействия должен учитывать качество классификационной модели, но не переоценивать его: прогноз воздействия остается умеренно точным, а не почти идеальным.

Блок 4. Регрессия

Текст задания. В каждом из заданий, если не сказано иного, необходимо использовать хотя бы 3 метода из следующих: случайный лес, метод наименьших квадратов, метод ближайших соседей и градиентный бустинг.

Ответ. В этом разделе решается задача прогнозирования непрерывной целевой переменной `monthly_spending`. Обозначим ее как Y_i , а вектор признаков клиента как X_i . Цель регрессионной модели - построить функцию $\hat{f}(X_i)$, которая приближает условное математическое ожидание:

$$\hat{Y}_i = \hat{f}(X_i) \approx E(Y_i | X_i).$$

В соответствии с условием задания переменная воздействия `premium_subscription` не включается в признаки. Это важно: если бы мы добавили воздействие в регрессионную модель прогноза, модель частично использовала бы информацию о `treatment`, что нарушило бы постановку блока регрессии и могло бы повлиять на последующий анализ эффектов воздействия.

Сначала подготавливаются данные, метрики и модели. Все модели обучаются и сравниваются на одном и том же `train/test split`, чтобы результаты были сопоставимы.

Задание 4.1

Текст задания. Отберите признаки, которые могут быть полезны при прогнозировании целевой (зависимой) переменной. Не включайте в число этих признаков переменную воздействия.

Ответ. Целевая переменная:

$$Y_i = \text{monthly_spending}_i.$$

Матрица признаков:

$$X_i = (\text{income}_i, \text{age}_i, \text{urban_area}_i, \text{family_size}_i, \text{free_trial_banner}_i).$$

Переменная воздействия $D_i = \text{premium_subscription}_i$ не входит в X_i .

переменная	роль
<code>monthly_spending</code>	целевая переменная
<code>income</code>	признак
<code>age</code>	признак
<code>urban_area</code>	признак
<code>family_size</code>	признак
<code>free_trial_banner</code>	признак

В качестве признаков используются доход, возраст, тип территории, размер семьи и инструмент `free_trial_banner`. Такой набор содержательно связан с месячными тратами: доход отражает платежеспособность, возраст - жизненный цикл клиента, городская территория - доступность сервиса, размер семьи - потенциальный объем потребления. `free_trial_banner` не является переменной воздействия; это инструментальная переменная из процесса генерации, поэтому ее включение не нарушает прямой запрет на `premium_subscription`. Важно, что здесь `free_trial_banner` используется только как прогнозный признак в регрессионной задаче. В блоке оценки эффектов воздействия без инструментальной переменной он не включается в `causal controls`, чтобы не смешивать обычную корректировку по наблюдаемым признакам с инструментальной вариацией.

Выборка разделена на обучающую и тестовую в пропорции 75/25:

показатель	значение
<code>n_train</code>	22500
<code>n_test</code>	7500
<code>test_share</code>	0.25

Тестовая часть составляет 25%, что соответствует требуемому интервалу от 20% до 30%.

Задание 4.2

Текст задания. Для каждого метода оцените $RMSE$ и $MAPE$, используя произвольные значения гиперпараметров на обучающей выборке, тестовой выборке и с помощью кросс-валидации. С помощью кросс-валидации на обучающей выборке подберите оптимальные значения гиперпараметров. В одной таблице укажите исходные и подобранные значения гиперпараметров, а также $RMSE$ и $MAPE$, рассчитанные на тестовой выборке и с помощью кросс-валидации до и после тюнинга. Обсудите наличие или отсутствие признаков переобучения модели и интерпретируйте полученные результаты.

Ответ. Используются четыре метода: МНК, KNN, случайный лес и градиентный бустинг, то есть больше минимально требуемых трех.

Метрики качества:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i)^2},$$

$$MAPE = \frac{1}{n} \sum_{i=1}^n \left| \frac{Y_i - \hat{Y}_i}{Y_i} \right| \cdot 100\%.$$

$RMSE$ измеряет типичный масштаб ошибки в единицах `monthly_spending`, поэтому используется как основной критерий сравнения. $MAPE$ показывает относительную ошибку и в таблицах приведен в процентах: например, значение 94.661 означает среднюю абсолютную процентную ошибку около 94.70%. В наших данных есть очень малые значения `monthly_spending`, поэтому $MAPE$ менее устойчива и используется только как дополнительная метрика, а не как основной критерий выбора лучшей модели.

Кросс-валидационная оценка строится как среднее по фолдам:

$$CV = \frac{1}{K} \sum_{k=1}^K Q_k,$$

где Q_k - значение метрики на validation-части k -го фолда.

Методы устроены следующим образом. МНК оценивает линейную зависимость:

$$\hat{Y}_i = \hat{\beta}_0 + X_i' \hat{\beta}.$$

KNN-регрессия прогнозирует значение по ближайшим соседям; поскольку расстояния зависят от масштаба признаков, используется стандартизация:

$$\tilde{X}_{ij} = \frac{X_{ij} - \bar{X}_j}{\hat{\sigma}_j}.$$

Случайный лес усредняет прогнозы деревьев:

$$\hat{f}_{RF}(x) = \frac{1}{B} \sum_{b=1}^B \hat{f}_b(x).$$

Градиентный бустинг строит ансамбль последовательно:

$$F_{m+1}(x) = F_m(x) + \gamma h_m(x),$$

где $h_m(x)$ - очередное дерево, а γ соответствует learning_rate.

Исходные гиперпараметры моделей

модель	исходные гиперпараметры
МНК	нет настраиваемых гиперпараметров
KNN	n_neighbors=25, weights=distance, StandardScaler
Случайный лес	max_depth=10, max_features=sqrt, n_estimators=100
Градиентный бустинг	max_depth=3, learning_rate=0.07, n_estimators=120

Качество до тюнинга

модель	RMSE train	MAPE train	RMSE test	MAPE test	RMSE-CV	MAPE-CV
МНК	5005.00	99.786	4983.14	97.411	5005.65	99.750
KNN	0.0000	0.0000	5004.85	99.046	5034.77	97.389
Случайный лес	4372.27	89.032	4749.34	99.927	4769.50	99.504
Градиентный бустинг	4672.24	95.501	4708.21	96.569	4729.15	96.689

По исходным гиперпараметрам лучший результат по RMSE test дает градиентный бустинг (4708.21), немного хуже работает случайный лес (4749.34), затем идут МНК и KNN. Это согласуется с устройством данных: зависимость monthly_spending от признаков нелинейная, поэтому ансамбли деревьев лучше аппроксимируют функцию $E(Y | X)$, чем линейная модель.

Особенно важен результат KNN: при weights="distance" на обучающей выборке RMSE = 0 и MAPE = 0. Это означает, что модель фактически запоминает train-наблюдения. Но на test и CV качество заметно хуже. Это классический признак переобучения.

Подбор гиперпараметров и итоговая таблица

Подбор выполнялся по RMSE на кросс-валидации. Формально выбиралась комбинация гиперпараметров:

$$\hat{\lambda} = \arg \min_{\lambda \in \Lambda} CV(\lambda).$$

модель	исходные гиперпараметры	подобранные гиперпараметры	RMSE train до	RMSE train после	MAPE train до	MAPE train после	RMSE test до	RMSE test после	MAPE test до	MAPE test после	RMSE-CV до	RMSE-CV после	MAPE-CV до	MAPE-CV после
Градиентный бустинг	max_depth=3, learning_rate=0.07, n_estimators=120	max_depth=10, learning_rate=0.07, n_estimators=120	4672.24	4659.32	95.501	93.603	4708.21	4710.36	96.569	94.661	4729.15	4728.38	96.689	95.459

модель	исходные гиперпараметры	подобранные гиперпараметры	RMSE train до	RMSE train после	MAPE train до	MAPE train после	RMSE test до	RMSE test после	MAPE test до	MAPE test после	RMSE-CV до	RMSE-CV после	MAPE-CV до	MAPE-CV после
Случайный лес	<code>max_depth=10, max_features=sqrt, n_estimators=100</code>	<code>max_depth=8, max_features=sqrt, n_estimators=120</code>	4372.27	4605.23	89.032	100.15	4749.34	4732.91	99.927	104.13	4769.50	4760.95	99.504	104.10
KNN	<code>n_neighbors=5, weights=distance</code>	<code>n_neighbors=45, weights=uniform</code>	4600.00	4660.88	0.0000	99.555	5004.85	4760.31	99.046	103.21	5034.77	4771.43	97.389	102.99
МНК	нет гиперпараметров	{}	5005.00	5005.00	99.786	99.786	4983.14	4983.14	97.411	97.411	5005.65	5005.65	99.750	99.750

После тюнинга минимальный RMSE test у градиентного бустинга (4710.36), далее идут случайный лес (4732.91) и KNN (4760.31), а МНК остается худшей по RMSE test (4983.14). Разница между градиентным бустингом и случайным лесом невелика: примерно 22.558 единицы RMSE, поэтому обе модели дают близкое качество.

Значения MAPE получаются большими, потому что в данных есть очень малые значения `monthly_spending`: даже умеренная абсолютная ошибка при малом знаменателе дает большой процент. Поэтому при содержательной интерпретации и выборе лучшей модели основное внимание уделяется RMSE, а MAPE используется как дополнительный индикатор устойчивости.

Диагностика переобучения

Для диагностики переобучения считаем разницу между качеством на тестовой и обучающей выборках после тюнинга:

$$Gap_{RMSE} = RMSE_{test} - RMSE_{train}.$$

модель	RMSE train после	RMSE test после	RMSE test-train gap	MAPE train после	MAPE test после	MAPE test-train gap
Случайный лес	4605.23	4732.91	127.68	100.15	104.13	3.984
KNN	4660.88	4760.31	99.430	99.555	103.21	3.653
Градиентный бустинг	4659.32	4710.36	51.033	93.603	94.661	1.059
МНК	5005.00	4983.14	-21.867	99.786	97.411	-2.375

После тюнинга наибольший разрыв между test и train по RMSE у случайного леса (127.68), затем у KNN (99.430). У градиентного бустинга разрыв меньше (51.033), поэтому его качество выглядит более устойчивым. МНК почти не переобучается, но из-за линейной формы хуже описывает нелинейную зависимость в данных.

Иными словами, у МНК проблема скорее в смещении модели, а у более гибких методов потенциальная проблема - дисперсия и переобучение. Лучший результат градиентного бустинга означает, что в этой задаче он дает наиболее удачный компромисс между гибкостью и обобщающей способностью.

Задание 4.3

Текст задания. На основании проделанного анализа выберите лучшую и худшую из обученных моделей. Обоснуйте сделанный выбор.

Ответ. Лучшие и худшие модели выбираются по RMSE на тестовой выборке после тюнинга:

$$RMSE_{test} = \sqrt{\frac{1}{n_{test}} \sum_{i \in test} (Y_i - \hat{Y}_i)^2}.$$

модель	RMSE test	MAPE test	RMSE gap vs best	MAPE gap vs best
Градиентный бустинг	4710.36	94.661	0.0000	0.0000
Случайный лес	4732.91	104.13	22.558	9.471
KNN	4760.31	103.21	49.958	8.546
МНК	4983.14	97.411	272.78	2.750

По выбранному критерию лучшей моделью является градиентный бустинг: его RMSE test = 4710.36. Худшая модель - МНК с RMSE test = 4983.14, что хуже лучшей модели примерно на 272.78 единицы целевой переменной.

Такой результат содержательно ожидаем. В процессе генерации данных заложены нелинейности и взаимодействия между признаками, поэтому линейная спецификация МНК слишком проста. Градиентный бустинг, напротив, последовательно строит ансамбль деревьев и лучше аппроксимирует нелинейную функцию $E(Y | X)$.

Задание 4.2, повышенная сложность

Текст задания. Подберите на обучающей выборке оптимальные значения гиперпараметров градиентного бустинга, ориентируясь на значение OOB (out-of-bag) ошибки. Сопоставьте гиперпараметры и точность на тестовой выборке для градиентного бустинга в зависимости от того, используется кросс-валидация или OOB ошибка.

Ответ. Реализуется stochastic gradient boosting с `subsample < 1`. При таком бустинге на каждой итерации часть наблюдений не попадает в подвыборку; именно они используются для внутренней out-of-bag диагностики. В отличие от случайного леса, где OOB-прогноз строится как голосование деревьев, для градиентного бустинга OOB является приближенной внутренней оценкой качества стохастического ансамбля. Поэтому ниже OOB используется как критерий подбора внутри этого класса моделей, а итоговое сравнение все равно проверяется на test.

Содержательно OOB-критерий можно интерпретировать как приближение среднеквадратичной ошибки на наблюдениях, которые не использовались соответствующими итерациями бустинга:

$$OOB\ error \approx \frac{1}{n} \sum_{i=1}^n (Y_i - \hat{Y}_i^{OOB})^2.$$

Преимущество OOB - обычно меньшая вычислительная стоимость по сравнению с полной кросс-валидацией. Недостаток - OOB доступна только для методов со случайными подвыборками и может быть менее универсальной для сравнения с другими моделями.

Лучшие OOB-конфигурации

best_params	OOB error	OOB RMSE
n_estimators=120, learning_rate=0.10, max_depth=3, subsample=0.60	21418050.00	4627.96
n_estimators=80, learning_rate=0.10, max_depth=3, subsample=0.80	21536320.00	4640.72
n_estimators=80, learning_rate=0.10, max_depth=3, subsample=0.60	21736060.00	4662.19
n_estimators=120, learning_rate=0.05, max_depth=3, subsample=0.60	21784020.00	4667.34

OOB-подбор выбрал конфигурацию `n_estimators=120, learning_rate=0.10, max_depth=3, subsample=0.60`; соответствующая OOB RMSE равна 4627.96.

Сравнение OOB и CV для градиентного бустинга

method	tuning_type	best_params	OOB error	CV score	test RMSE	test MAPE
GradientBoostingRegressor	OOB	n_estimators=120, learning_rate=0.10, max_depth=3, subsample=0.60	21418050.00	—	4710.77	94.355
GradientBoostingRegressor	CV on same grid	n_estimators=120, learning_rate=0.10, max_depth=3, subsample=0.80	—	4725.10	4709.17	94.647
Градиентный бустинг	main regression block	learning_rate=0.10, max_depth=3, n_estimators=120	—	4728.38	4710.36	94.661

На тестовой выборке CV-вариант оказался немного лучше по RMSE: 4709.17 против 4710.77 у OOB-варианта. По MAPE немного лучше OOB-вариант: 94.355 против 94.647, но из-за очень малых значений monthly_spending эта метрика менее устойчива.

OOB и CV приводят к очень похожим моделям, различается только доля подвыборки subsample. Существенных признаков сильного переобучения у OOB-модели нет: ее тестовое качество близко к CV-варианту и к лучшему градиентному бустингу из основного блока. В качестве основного критерия здесь разумно оставить RMSE, поэтому на тесте предпочтительнее CV-подбор, хотя различие с OOB-подбором очень небольшое.

Численная зависимость OOB RMSE от числа деревьев

n_estimators	OOB RMSE
40	4760.89
80	4662.19
120	4627.96
160	4650.54
200	4626.38

Ошибка заметно снижается при переходе от 40 к 120 деревьям. После этого изменения небольшие: при 160 деревьях ошибка временно растет, а при 200 снова почти возвращается к минимуму. Это говорит о том, что увеличение числа деревьев дает ограниченный дополнительный выигрыш.

Задание 4.4, повышенная сложность

Текст задания. Включите в анализ дополнительный метод регрессии, не рассматривавшийся в курсе и не представленный в библиотеке `scikit-learn`. Опишите данный метод: принцип работы, преимущества и недостатки. Осуществите тюнинг гиперпараметров и сопоставьте его точность на тестовой выборке с точностью лучшего из обученных ранее методов.

Ответ. В качестве внешнего метода используется `CatBoostRegressor` из библиотеки `catboost`. CatBoost - это градиентный бустинг над деревьями решений. Как и обычный бустинг, он строит модель в виде суммы базовых деревьев:

$$\hat{f}_M(x) = \sum_{m=0}^M \gamma_m h_m(x).$$

Основные плюсы CatBoost: хорошая работа с табличными данными, способность улавливать нелинейности и взаимодействия признаков, встроенная регуляризация и устойчивость при аккуратном тюнинге. Основные

минусы: меньшая интерпретируемость по сравнению с МНК, риск переобучения при слишком сложной настройке, внешняя зависимость и необходимость подбора гиперпараметров.

Для тюнинга используется validation-подход:

$$train \rightarrow train_{inner} \cup validation.$$

Лучшие параметры выбирались по validation RMSE:

$$\hat{\lambda}_{CatBoost} = \arg \min_{\lambda \in \Lambda} RMSE_{valid}(\lambda).$$

Тюнинг CatBoost

best_params	validation RMSE	validation MAPE
iterations=200, depth=3, learning_rate=0.10, l2_leaf_reg=3	4701.59	87.809
iterations=200, depth=3, learning_rate=0.10, l2_leaf_reg=10	4703.71	87.663
iterations=200, depth=4, learning_rate=0.10, l2_leaf_reg=3	4703.94	88.543
iterations=200, depth=4, learning_rate=0.10, l2_leaf_reg=10	4704.32	88.170

Лучшие гиперпараметры по validation RMSE: iterations=200, depth=3, learning_rate=0.10, l2_leaf_reg=3.

Сравнение CatBoost с лучшей моделью основного блока

method	source	best_params	validation/CV RMSE	test RMSE	test MAPE	RMSE gap vs main best	MAPE gap vs main best
Градиентный бустинг	основной блок регрессии	learning_rate=0.10, max_depth=3, n_estimators=120	4728.38	4710.36	94.661	0.0000	0.0000
CatBoostRegressor	дополнительный внешний метод	iterations=200, depth=3, learning_rate=0.10, l2_leaf_reg=3	4701.59	4698.18	94.003	-12.174	-0.659

CatBoost дал RMSE = 4698.18 и MAPE = 94.003 на тестовой выборке. Это лучше лучшей модели из основного блока, градиентного бустинга из sklearn, у которого RMSE = 4710.36 и MAPE = 94.661. Улучшение по RMSE составляет примерно 12.174 единицы целевой переменной, а по MAPE примерно 0.659.

Следовательно, в этой задаче CatBoost дает небольшое, но заметное улучшение качества. Это содержательно объяснимо: CatBoost, как более продвинутый вариант бустинга над деревьями, лучше подстраивается под нелинейности и взаимодействия в табличных данных. При этом выигрыш не огромный, поэтому с практической точки зрения нужно учитывать и стоимость внешней зависимости. Основной вывод лучше делать по RMSE, потому что MAPE остается менее устойчивой метрикой из-за очень малых значений monthly_spending.

Задание 4.5

Текст задания. В случае необходимости проведите дополнительный анализ.

Ответ. Дополнительный анализ в блоке регрессии был проведен в рамках двух пунктов повышенной сложности: ООВ-подбор градиентного бустинга и внешний метод CatBoost. Эти проверки показали, что стандартный градиентный бустинг из основного блока уже дает устойчивое качество, ООВ и CV выбирают очень похожие модели, а CatBoost немного улучшает тестовый RMSE. Отдельный дополнительный анализ сверх этих пунктов не потребовался.

5 Эффекты воздействия

При выполнении данного задания необходимо объединить обучающую и тестовую выборки в одну.

Далее каждый пункт оформлен в формате: номер задания, формулировка задания, ответ.

Подключим библиотеки, которые используются в семинаре по эффектам воздействия: `statsmodels` для МНК, `doubleml` для двойного машинного обучения и модели `sklearn` для оценки условных средних и вероятностей.

Сначала загрузим полную выборку, обучающую и тестовую части, а также полный симуляционный датасет с потенциальными исходами из раздела 2.

Проверка объединенной выборки

датасет	число наблюдений
<code>df</code>	30000
<code>df_full</code>	30000
<code>df_train</code>	22500
<code>df_test</code>	7500
<code>df_train + df_test</code>	30000

Наблюдаемые колонки: `monthly_spending`, `premium_subscription`, `income`, `age`, `urban_area`, `family_size`, `free_trial_banner`.

В полной выборке 30000 наблюдений: 22500 из обучающей части и 7500 из тестовой. Значит для раздела 5 используется объединенная выборка, как требуется в задании.

В `df_full.csv` сохранены наблюдаемые переменные, потенциальные исходы и служебные переменные симуляции из раздела 2. Поэтому для расчета истинных ATE, LATE и CATE повторная генерация данных здесь не нужна.

Далее проверим согласованность наблюдаемых колонок и будем использовать сохраненные потенциальные исходы.

Инструментальная переменная `free_trial_banner` уже сохранена в полном датасете вместе с вероятностью и индексом ее генерации.

Потенциальные значения переменной воздействия `premium1` и `premium0` также читаются из полного датасета. Разница между ними нужна для выделения наблюдателей при расчете LATE.

Потенциальные исходы зависимой переменной `monthly_spending0` и `monthly_spending1` читаются из полного датасета.

Проверим, что наблюдаемые переменные в `df_full.csv` совпадают с сохраненным `df.csv`. После этого будем использовать полный датасет для доступа к потенциальным исходам, которые в реальных данных были бы ненаблюдаемыми.

Проверка совпадения наблюдаемых переменных в `df.csv` и `df_full.csv`

переменная	совпадает
<code>monthly_spending</code>	True
<code>premium_subscription</code>	True
<code>income</code>	True
<code>age</code>	True
<code>urban_area</code>	True
<code>family_size</code>	True
<code>free_trial_banner</code>	True

Все наблюдаемые переменные совпадают. Значит потенциальные исходы и служебные переменные загружены из той же генерации данных, что и наблюдаемый `df.csv`.

Истинные ATE, LATE, ATET и распределение истинного CATE будем считать на полной объединенной выборке из 30000 наблюдений. После этого, как разрешено в примечании к заданию, для оценок по наблюдаемым данным используем рабочую подвыборку из 10000 наблюдений.

Полная выборка используется для эталонных эффектов из потенциальных исходов. Рабочая подвыборка содержит те же наблюдаемые переменные, потенциальные исходы `monthly_spending0`, `monthly_spending1`, условные средние `g0`, `g1` и тип клиента относительно инструмента. Все дальнейшие оценки, основанные только на наблюдаемых данных, считаются на этой рабочей подвыборке.

5.1

Задание. Математически запишите выражения для ATE и LATE (с учетом специфики обозначений ваших переменных). Содержательно проинтерпретируйте, что они отражают в вашем исследовании.

Ответ.

В обозначениях проекта `monthly_spending1` — потенциальные месячные траты клиента при наличии премиум-подписки, а `monthly_spending0` — потенциальные месячные траты без премиум-подписки.

Средний эффект воздействия:

$$ATE = E(monthly_spending1_i - monthly_spending0_i).$$

Он показывает, насколько в среднем меняются месячные траты клиента при переходе к премиум-подписке.

Локальный средний эффект воздействия:

$$LATE = E(monthly_spending1_i - monthly_spending0_i \mid premium1_i > premium0_i).$$

Он показывает средний эффект подписки для наблюдателей: клиентов, которые оформили бы премиум-подписку при показе баннера и не оформили бы ее без баннера.

Здесь индикатор воздействия наблюдается как

$$premium_subscription_i = \begin{cases} premium1_i, & \text{если } free_trial_banner_i = 1 \\ premium0_i, & \text{если } free_trial_banner_i = 0 \end{cases}$$

Поэтому различие между ATE и LATE содержательно связано с тем, что инструмент меняет решение о подписке не у всех клиентов, а только у части из них.

5.2

Задание. Используя симулированные вами, но недоступные в реальных данных потенциальные исходы (гипотетические значения), получите оценки среднего эффекта воздействия, условных средних эффектов воздействия и локального среднего эффекта воздействия. Для ATE и LATE результаты представьте в форме таблицы, а для CATE постройте гистограмму или ядерную оценку функции плотности. Проинтерпретируйте полученные значения.

Ответ.

Сначала рассчитаем индивидуальные эффекты воздействия как разность двух потенциальных исходов:

$$TE_i = monthly_spending1_i - monthly_spending0_i.$$

Тогда средний эффект воздействия можно оценить напрямую как:

$$\widehat{ATE} = \frac{1}{n} \sum_{i=1}^n TE_i.$$

Локальный средний эффект воздействия для наблюдателей оценивается как:

$$\widehat{LATE} = \frac{1}{n_c} \sum_{i: premium1_i > premium0_i} TE_i,$$

где n_c — число наблюдателей.

Условный средний эффект воздействия в симуляции имеет вид:

$$CATE_i = E(monthly_spending1_i | X_i) - E(monthly_spending0_i | X_i).$$

В нашем случае $g0$ и $g1$ из DGP зависят не только от наблюдаемых признаков `income`, `age`, `urban_area`, `family_size`, но и от скрытой `online_preference`. Поэтому далее истинный CATE трактуется как `oracle/simulation CATE` по полной DGP с учетом скрытой компоненты. Это не тот же объект, что идентифицируемый в реальных данных CATE только по наблюдаемым X : `oracle`-версия нужна здесь как симуляционный эталон для сравнения качества методов.

Первые значения показывают, что эффект премиум-подписки неодинаков для разных клиентов. Это ожидаемо, потому что в генерации эффект зависит от дохода, города, размера семьи, возраста и ненаблюдаемой онлайн-склонности.

Оценим ATE, LATE и ATET напрямую по потенциальным исходам на полной объединенной выборке. Такая возможность есть только в симуляции, поэтому эти величины играют роль эталона, относительно которого затем удобно сравнивать оценки на наблюдаемых данных.

Содержательно получаем следующую картину. Истинный средний эффект воздействия равен примерно 6293, то есть премиум-подписка в среднем заметно увеличивает месячные траты клиента. Истинный локальный эффект LATE равен примерно 6280 и очень близок к ATE. Это означает, что для наблюдателей, то есть клиентов, которых можно подтолкнуть к подписке показом баннера, эффект подписки примерно сопоставим со средним эффектом по всей выборке.

Оценка ATET выше, около 7275, что естественно интерпретируется как более сильный эффект среди тех клиентов, которые в наблюдаемой выборке реально получили воздействие. Уже на этом шаге видно, что разные целевые параметры относятся к разным группам клиентов, поэтому в дальнейшем нельзя механически сопоставлять ATE, ATET и LATE как одно и то же число.

Истинные эффекты по потенциальным исходам

параметр	оценка
ATE	6292.96
LATE	6280.32
ATET	7274.64

На полной объединенной выборке средний эффект подписки положителен: премиум-подписка заметно увеличивает месячные траты. LATE относится не ко всем клиентам, а к наблюдателям: тем, чье решение о подписке меняется под воздействием баннера.

Теперь рассчитаем CATE как разность условных средних потенциальных исходов и построим гистограмму распределения условных эффектов.

Распределение истинного CATE



Первые значения CATE_full: 7783.72, 6017.36, 5772.28, 939.15, 6502.53, 5183.60, 8234.62, 5998.70, 6951.41, 8082.29.

Распределение CATE показывает гетерогенность эффекта: премиум-подписка приносит разный прирост месячных трат для разных сегментов клиентов.

5.3

Задание. Оцените средний эффект воздействия как разницу в средних по выборкам тех, кто получил и не получил воздействие. Опишите недостатки соответствующего подхода с учетом специфики рассматриваемой вами экономической проблемы.

Ответ.

Наивная оценка опирается на допущение независимости:

$$E(\text{monthly_spending}_{1i} \mid \text{premium_subscription}_i = 1) = E(\text{monthly_spending}_{1i}),$$

$$E(\text{monthly_spending}_{0i} \mid \text{premium_subscription}_i = 0) = E(\text{monthly_spending}_{0i}).$$

Тогда средний эффект воздействия оценивается как разница выборочных средних:

$$\widehat{ATE}_{naive} = \frac{1}{n_1} \sum_{i: \text{premium_subscription}_i = 1} \text{monthly_spending}_i - \frac{1}{n_0} \sum_{i: \text{premium_subscription}_i = 0} \text{monthly_spending}_i.$$

В нашей задаче это допущение не выполняется, потому что на решение о подписке и на траты одновременно влияет ненаблюдаемая `online_preference`.

Наивная оценка ATE

параметр	оценка
ATE oracle	6292.96
ATE naive	9883.19

Наивная оценка оказывается существенно выше истинного ATE: примерно 9883 против 6293. Следовательно, простая разница средних завышает эффект подписки примерно на 3590 денежных единиц.

Как и в семинарской логике, это завышение связано с тем, что разница средних смешивает два эффекта:

$$E(\text{monthly_spending}_i \mid \text{premium_subscription}_i = 1) - E(\text{monthly_spending}_i \mid \text{premium_subscription}_i = 0) = ATE + \text{selection bias}.$$

В нашей задаче смещение возникает из-за самоотбора: клиенты с большей склонностью к онлайн-покупкам чаще оформляют премиум-подписку и одновременно больше тратят даже без нее. Поэтому наивная разница средних улавливает не только причинный эффект подписки, но и исходные различия между группами. Именно из-за этого для корректного анализа нужны методы, которые хотя бы частично контролируют наблюдаемую неоднородность, а при наличии эндогенности затем и инструментальный подход.

5.4

Задание. Используя оценки, полученные лучшими из обученных ранее классификационных и регрессионных моделей, оцените средний эффект воздействия с помощью: метода наименьших квадратов; условных математических ожиданий; взвешивания на обратные вероятности; метода, обладающего двойной устойчивостью; двойного машинного обучения. Сравните результаты и назовите ключевую предпосылку этих методов. Содержательно обсудите причины, по которым она может соблюдаться или нарушаться в вашем случае. Приведите содержательную экономическую интерпретацию оценки среднего эффекта воздействия.

Ответ.

Подготовим признаки и лучшие модели из разделов 3 и 4. Здесь под лучшими моделями понимаются лучшие модели из основных методов курса, без внешнего CatBoost из повышенной сложности блока 4. Это осознанное ограничение: CatBoost действительно дал чуть меньший RMSE в блоке 4, но он был добавлен как внешний benchmark повышенной сложности; для сопоставимости с семинарскими causal-методами в блоке 5 используем лучшие sklearn-модели из основной линейки. В блоке 5 из предыдущих разделов переносятся архитектуры и гиперпараметры, а сами nuisance-модели переобучаются на causal controls income, age, urban_area, family_size без инструмента free_trial_banner. Поэтому метрики ниже используются как обоснование выбора класса модели, а не как качество ровно той же матрицы признаков.

В разделе 3 лучший классификатор из основных методов выбран по максимальному AUC на тестовой выборке: это градиентный бустинг (AUC = 0.764) с параметрами `n_estimators = 100`, `learning_rate = 0.10`, `max_depth = 2`. Этот критерий подходит для propensity score, потому что нам важна не только бинарная метка, но и качество ранжирования клиентов по вероятности подписки.

В разделе 4 лучшая регрессионная модель из основных методов выбрана по минимальному RMSE на тестовой выборке после тюнинга: это градиентный бустинг (RMSE test = 4710.36) с параметрами `n_estimators = 120`, `learning_rate = 0.10`, `max_depth = 3`. RMSE используется как основной критерий, потому что MAPE менее устойчив из-за малых значений `monthly_spending`.

Основная предпосылка методов этого пункта — условная независимость воздействия после учета наблюдаемых признаков:

$$\begin{aligned} E(\text{monthly_spending}_{1i} \mid \text{premium_subscription}_i = 1, X_i) &= E(\text{monthly_spending}_{1i} \mid X_i), \\ E(\text{monthly_spending}_{0i} \mid \text{premium_subscription}_i = 0, X_i) &= E(\text{monthly_spending}_{0i} \mid X_i). \end{aligned}$$

Если она выполнена, то различия между клиентами с подпиской и без подписки можно скорректировать с помощью наблюдаемых признаков $X = (\text{income}, \text{age}, \text{urban_area}, \text{family_size})$.

Эти модели используются как nuisance-модели: регрессия оценивает условные средние трат, а классификатор оценивает вероятность получения воздействия.

Сначала оценим АТЕ с помощью МНК, отдельно аппроксимируя месячные траты для клиентов с подпиской и без подписки. Это повторяет идею из семинара: мы строим две модели условных математических ожиданий, а затем усредняем разность предсказаний по всей выборке.

При таком подходе

$$\widehat{ATE}_{LS} = \frac{1}{n} \sum_{i=1}^n \left(\widehat{E}(\text{monthly_spending}_{1_i} | X_i) - \widehat{E}(\text{monthly_spending}_{0_i} | X_i) \right),$$

а индивидуальная разность прогнозов дает оценку условного эффекта

$$\widehat{CATE}_i^{LS} = \widehat{E}(\text{monthly_spending}_{1_i} | X_i) - \widehat{E}(\text{monthly_spending}_{0_i} | X_i).$$

То есть МНК здесь выступает не только как способ получить средний эффект, но и как первый, самый простой способ аппроксимировать гетерогенность воздействия по наблюдаемым признакам.

АТЕ по МНК

параметр	оценка
ATE oracle	6292.96
ATE naive	9883.19
ATE ls	8034.57

Оценка АТЕ_ls равна примерно 8035, то есть она заметно ниже наивной оценки, но все еще существенно выше истинного АТЕ = 6293. Это означает, что учет наблюдаемых признаков действительно снимает часть селекционного смещения, но не устраняет его полностью.

Причина в том, что линейная спецификация остается достаточно грубой по сравнению с истинным механизмом генерации данных, а ненаблюдаемая online_preference вообще не входит в модель. Поэтому МНК корректирует различия по income, age, urban_area и family_size, но не может удалить смещение, связанное со скрытой склонностью к онлайн-потреблению. Содержательно это хороший первый benchmark: он лучше наивной разницы средних, но еще не решает проблему эндогенности.

Теперь оценим АТЕ через условные математические ожидания с помощью T-learner: одна модель обучается на клиентах без подписки, вторая — на клиентах с подпиской.

В терминах семинара это оценка вида

$$\widehat{CATE}_i^T = \widehat{E}(\text{monthly_spending}_i | X_i, \text{premium_subscription}_i = 1) - \widehat{E}(\text{monthly_spending}_i | X_i, \text{premium_subscription}_i = 0),$$

а средний эффект воздействия получается усреднением этих условных эффектов:

$$\widehat{ATE}^T = \frac{1}{n} \sum_{i=1}^n \widehat{CATE}_i^T.$$

АТЕ через условные математические ожидания

параметр	оценка
ATE oracle	6292.96
ATE naive	9883.19
ATE ls	8034.57

параметр	оценка
ATE conditional means	7840.64

T-learner также дает оценку выше истинного ATE. Метод лучше учитывает нелинейности, но не решает проблему ненаблюдаемой переменной, влияющей и на подписку, и на траты.

Оценим ATE с помощью DoubleML без инструментальной переменной. Как и в семинаре, здесь используются две nuisance-функции:

$$g(d, X_i) = E(\text{monthly_spending}_i \mid \text{premium_subscription}_i = d, X_i),$$

$$m(X_i) = P(\text{premium_subscription}_i = 1 \mid X_i).$$

Затем эти оценки подставляются в ортогонализированную moment-функцию. Идея такого подхода в том, что итоговая оценка становится менее чувствительной к малым ошибкам в оценивании вспомогательных объектов, а cross-fitting помогает уменьшить переобучение.

По сравнению с простыми plug-in методами DML особенно полезен тогда, когда условные средние и propensity score оцениваются гибкими ML-моделями, а не жесткими линейными спецификациями.

DoubleML без инструмента

показатель	значение
ATE dml standard	7810.00
std err	74.435
95% CI lower	7664.11
95% CI upper	7955.89

Оценка DoubleML без инструмента равна примерно 7810, то есть она ближе к истинному ATE, чем наивная оценка и МНК, но все равно остается завышенной. Это хорошо согласуется с экономическим содержанием задачи.

DoubleMLIRM интерпретируется как оценка ATE только при допущении условной независимости потенциальных исходов и воздействия после контроля на X. В нашей генерации это допущение нарушено, потому что скрытая online_preference влияет и на вероятность подписки, и на итоговые траты. Поэтому даже современный полупараметрический метод с ML nuisance-моделями не может полностью устранить смещение, если ключевая ненаблюдаемая переменная отсутствует в данных.

Далее используем IPW: сначала оценим вероятность подписки по наблюдаемым признакам, затем построим взвешенный псевдоисход.

IPW-оценка среднего эффекта воздействия имеет вид:

$$\widehat{ATE}^{IPW} = \frac{1}{n} \sum_{i=1}^n \frac{\text{premium_subscription}_i \cdot \text{monthly_spending}_i}{\hat{P}(\text{premium_subscription}_i = 1 \mid X_i)} - \frac{(1 - \text{premium_subscription}_i) \cdot \text{monthly_spending}_i}{1 - \hat{P}(\text{premium_subscription}_i = 1 \mid X_i)}.$$

Здесь веса корректируют несбалансированность между treated и control группами по наблюдаемым признакам.

IPW и диагностика propensity score

показатель	оценка
min propensity	0.012
max propensity	0.950
ATE IPW	7816.84

Оцененные вероятности не равны 0 или 1, поэтому IPW применим технически. Содержательно результат также опирается на условную независимость и поэтому не полностью устраняет эндогенность подписки.

Теперь рассчитаем DR-оценку. Как и в семинаре, она объединяет outcome-модели и propensity score, поэтому обладает свойством двойной устойчивости.

Формально

$$\widehat{ATE}^{DR} = \frac{1}{n} \sum_{i=1}^n \widehat{E}(\text{monthly_spending}_i \mid X_i, T_i = 1) - \widehat{E}(\text{monthly_spending}_i \mid X_i, T_i = 0) + \frac{T_i \cdot (\text{monthly_spending}_i - \widehat{E}(\text{monthly_spending}_i \mid X_i, T_i = 1))}{P(T_i = 1 \mid X_i)} - \frac{(1 - T_i) \cdot (\text{monthly_spending}_i - \widehat{E}(\text{monthly_spending}_i \mid X_i, T_i = 0))}{1 - P(T_i = 1 \mid X_i)}.$$

Преимущество состоит в том, что при корректной спецификации хотя бы одной из двух частей, модели исхода или модели вероятности воздействия, оценка сохраняет состоятельность. Поэтому DR удобно рассматривать как более надежный benchmark, чем чистый outcome-regression или чистый IPW.

Сравнение ATE до PSM

метод	оценка
ATE oracle	6292.96
ATE naive	9883.19
ATE ls	8034.57
ATE conditional means	7840.64
ATE dml standard	7810.00
ATE IPW	7816.84
ATE DR	7819.54

Сводная таблица показывает, что все методы на наблюдаемых данных дают положительный эффект подписки, но практически все они завышают истинный ATE = 6293. Наивная оценка максимальна, что соответствует сильному смещению отбора. После учета наблюдаемых признаков оценки снижаются: ATE conditional means ≈ 7841, ATE dml standard ≈ 7810, ATE IPW ≈ 7817, ATE DR ≈ 7820.

Наиболее близкими к истинному ATE среди этих методов оказываются T-learner, DML, IPW и DR, но даже они остаются выше эталона. Содержательно это означает, что контроль по наблюдаемым переменным действительно убирает часть смещения, но скрытая online_preference не позволяет полностью восстановить причинный эффект на основе только условия условной независимости.

Экономическая интерпретация при этом стабильна: премиум-подписка повышает траты, но если игнорировать ненаблюдаемую селекцию, масштаб эффекта легко переоценить.

Повышенная сложность. Ответ. В качестве дополнительного метода оценки ATE используем Propensity Score Matching.


Как и в классической постановке из семинарской логики, сначала оценивается propensity score

$$p(X_i) = P(\text{premium_subscription}_i = 1 \mid X_i),$$

после чего treated и control наблюдения сопоставляются по близости этих вероятностей. Идея PSM состоит в том, что если после conditioning на $p(X)$ распределения наблюдаемых признаков в группах становятся близкими, то сравнение исходов внутри matched-пар лучше приближает причинный эффект, чем сырая разница средних.

В текущем ноутбуке для оценки propensity score используется логистическая регрессия со стандартизацией признаков, а затем применяется симметричное nearest-neighbor matching. Такой выбор остается достаточно простым, хорошо интерпретируется и соответствует классическому изложению метода.

PSM: common support и caliper



показатель	оценка
нижняя граница support	0.067
верхняя граница support	0.966
доля на общей support	0.999
caliper по logit propensity	0.175

Почти вся выборка находится на общей support, однако нижняя граница propensity score близка к нулю. Поэтому для методов, основанных на обратных вероятностях, далее важно контролировать экстремальные веса: формально нулевых вероятностей нет, но слабый overlap может повышать дисперсию оценок.

Для оценки ATE применим симметричное nearest-neighbor matching с возвращением: propensity score оценивается логистической регрессией, а matching и caliper считаются в одной шкале logit propensity score.

Для каждого клиента с подпиской подбирается ближайший клиент без подписки, а для каждого клиента без подписки — ближайший клиент с подпиской. После этого индивидуальные matched-разности усредняются по общей support. Такой вариант удобен тем, что он ориентирован именно на оценку среднего эффекта воздействия по всей рабочей выборке, а не только на АТТ.

Идея общей support здесь принципиальна: сравнивать можно только те наблюдения, для которых в противоположной группе есть достаточно похожие аналоги по propensity score; само расстояние при matching считается по logit_ps.

PSM: matched estimate

показатель	оценка
matched treated	4914
matched control	5072
ATE PSM	8019.06
PSM - true ATE	1726.10
PSM - true ATE	1726.10

Проверим баланс контрольных переменных до и после matching с помощью standardized mean differences. Здесь SMD before считается не на всей исходной выборке, а на наблюдениях общей support до matching:

$$SMD(X_j) = \frac{\bar{X}_{1j} - \bar{X}_{0j}}{\sqrt{\frac{Var(X_{1j}) + Var(X_{0j})}{2}}}.$$

Именно так, как обсуждается в стандартной теории matching, после хорошего сопоставления абсолютные значения SMD должны уменьшаться и становиться близкими к нулю. В наших результатах это и происходит: по всем контрольным переменным баланс после matching заметно улучшается.

При этом сама ATE PSM оценка остается около 8019, то есть все равно заметно выше истинного ATE. Следовательно, PSM хорошо выравнивает наблюдаемую часть различий между группами, но не может убрать смещение, вызванное ненаблюдаемой `online_preference`.

PSM: баланс covariates и итоговая ATE-таблица

переменная	SMD before	SMD after	SMD before	SMD after
income	0.455	-0.0090	0.455	0.0090
age	-0.274	-0.0070	0.274	0.0070
urban_area	0.458	0.017	0.458	0.017
family_size	0.289	-0.016	0.289	0.016

метод	оценка
ATE oracle	6292.96
ATE naive	9883.19
ATE ls	8034.57
ATE conditional means	7840.64
ATE dml standard	7810.00
ATE IPW	7816.84
ATE DR	7819.54
ATE PSM	8019.06

Propensity Score Matching хорошо подходит здесь как дополнительный метод оценки ATE, потому что он напрямую решает задачу сопоставления treated и control клиентов по наблюдаемым признакам. По сравнению с IPW метод обычно менее чувствителен к экстремальным весам, а по сравнению с OLS и T-learner делает акцент именно на сопоставимости групп. Слабая сторона PSM состоит в возможной потере наблюдений вне общей support и в том, что метод по-прежнему не устраняет смещение из-за ненаблюдаемой `online_preference`.

В наших данных PSM заметно улучшает баланс наблюдаемых признаков: абсолютные SMD после matching становятся очень малыми. Однако сама оценка ATE PSM равна примерно 8019, то есть все равно заметно выше истинного ATE = 6293. Поэтому содержательный вывод такой: как дополнительный метод для пункта 5.4 PSM зашел хорошо, но полностью проблему эндогенности он не решает.

5.5

Задание. Оцените условные средние эффекты воздействия с помощью: метода наименьших квадратов; S-learner; T-learner; метода трансформации классов; X-learner. Сравните результаты и обсудите, насколько в вашем случае мотивированы применение метода X-learner. Опишите, как можно было бы использовать полученные вами оценки в бизнесе или при реализации государственных программ.

Ответ.

Напомним, что условный средний эффект воздействия определяется как

$$CATE_i = E(monthly_spending1_i | X_i) - E(monthly_spending0_i | X_i).$$

CATE по МНК и T-learner уже были рассчитаны выше. Теперь оценим CATE с помощью S-learner: обучим одну модель на признаках и индикаторе подписки, а затем подставим каждому клиенту оба значения воздействия.

S-learner использует одну общую модель для обеих групп и восстанавливает эффект через разность двух counterfactual-прогнозов одной и той же функции. Это удобно, потому что вся выборка используется совместно, а сама процедура вычислительно проста.

Однако, как и подчеркивается в семинарской теории, при слабом сигнале воздействия или при очень разных структурных зависимостях в treated и control группах такой подход может сглаживать индивидуальные эффекты.

Одна общая модель может слишком сильно усреднять поведение двух режимов и тем самым недооценивать или переоценивать heterogeneity.

Оценим CATE методом трансформации классов: модель обучается прогнозировать IPW-псевдоисход, который является шумной индивидуальной оценкой эффекта.

В этом подходе сначала строится псевдоисход

$$monthly_spending_i^* = \frac{premium_subscription_i \cdot monthly_spending_i}{\hat{P}(premium_subscription_i = 1 | X_i)} - \frac{(1 - premium_subscription_i) \cdot monthly_spending_i}{1 - \hat{P}(premium_subscription_i = 1 | X_i)},$$

а затем оценивается условное математическое ожидание

$$\widehat{CATE}_i^{CT} = \widehat{E}(monthly_spending_i^* | X_i).$$

Метод трансформации классов прост в реализации, потому что сводит задачу оценки CATE к обычной задаче регрессии на псевдоисход. Но цена этой простоты — высокая дисперсия.

В наших результатах это видно особенно хорошо: СТ дает самый высокий MSE0 среди рассмотренных CATE-методов. Это означает, что в данной задаче шум в IPW-псевдоисходах слишком велик, и модель хуже восстанавливает индивидуальную гетерогенность эффекта, чем S-learner, X-learner и даже T-learner.

Оценим CATE с помощью X-learner. Сначала строятся имитированные эффекты для treated и control групп, затем эти эффекты прогнозируются и объединяются с весами, связанными с вероятностью подписки.

Для клиентов с подпиской и без подписки строятся две вспомогательные величины:

$$\begin{aligned} D1_i &= monthly_spending_i - \widehat{E}(monthly_spending_{0i} | X_i), & premium_subscription_i &= 1, \\ D0_i &= \widehat{E}(monthly_spending_{1i} | X_i) - monthly_spending_i, & premium_subscription_i &= 0. \end{aligned}$$

После этого оцениваются условные ожидания этих величин и объединяются в итоговую оценку

$$\widehat{CATE}_i^X = \hat{p}(X_i) \cdot \widehat{E}(D0_i | X_i) + (1 - \hat{p}(X_i)) \cdot \widehat{E}(D1_i | X_i),$$

где $\hat{p}(X_i)$ — оцененная вероятность подписки.

X-learner особенно мотивирован в нашей задаче по двум причинам, как и в семинаре. Во-первых, сам эффект подписки гетероген. Во-вторых, treated и control группы различаются по составу, поэтому полезно отдельно использовать информацию о псевдоэффектах, получаемых внутри каждой группы.

Именно поэтому X-learner часто работает лучше в задачах, где есть структурная неоднородность и разная информативность двух подвыборок. В наших данных этот вывод подтверждается численно: по MSE0 именно X-learner показывает наилучшее качество восстановления истинного CATE.

Повышенная сложность. Ответ. В качестве дополнительного метода повышенной сложности оценим CATE с помощью R-learner. Идея метода состоит в том, чтобы сначала убрать из monthly_spending и premium_subscription часть, объясняемую наблюдаемыми признаками, а затем восстанавливать гетерогенный эффект по остаткам.

Базовое уравнение имеет вид

$$monthly_spending_i - m(X_i) = \tau(X_i) \cdot (premium_subscription_i - e(X_i)) + \varepsilon_i,$$

где $m(X_i) = E(monthly_spending_i | X_i)$, $e(X_i) = P(premium_subscription_i = 1 | X_i)$, а $\tau(X_i)$ — искомый условный эффект воздействия. Такой подход хорошо подходит здесь как дополнительный метод CATE, потому что он отдельно моделирует outcome и propensity score, а затем оценивает именно гетерогенный эффект.

R-learner: основные результаты

показатель	оценка
share kept after trimming	1.000
mean R-learner CATE	7582.08
mean R-learner CATE - true ATE	1289.12
mean individual bias	1293.64


В R-learner мы используем residualization-подход: сначала оцениваем $m(X)$ и $e(X)$, затем переходим к остаткам исхода и воздействия. Это упрощенная реализация R-learner без cross-fitting, поэтому возможна зависимость от качества nuisance-моделей и переобучения.

Фактически оценивается уравнение

$$monthly_spending_i - \hat{m}(X_i) \approx \tau(X_i) \cdot (premium_subscription_i - \hat{e}(X_i)).$$

Небольшой trimming по наблюдениям с почти нулевым остатком воздействия нужен для численной устойчивости. Если величина $premium_subscription_i - \hat{e}(X_i)$ слишком мала, то псевдоисход становится нестабильным и может искусственно увеличивать дисперсию оценки CATE.

Распределение CATE по R-learner



R-learner занимает промежуточное место между уже использованными подходами. По сравнению с S-learner он меньше зависит от того, насколько одна общая модель умеет различать treatment heterogeneity. По сравнению с T-learner он эффективнее использует общую информацию о вероятности подписки и среднем уровне исхода. По сравнению с методом трансформации классов R-learner обычно устойчивее, потому что не строится напрямую только на шумном IPW-псевдоисходе. По сравнению с X-learner его плюс в явной residualization-логике, а минус в чувствительности к качеству nuisance-моделей $m(X)$ и $e(X)$.

На наших данных R-learner дает средний CATE ≈ 7582 , то есть по среднему уровню он ближе к истинному ATE, чем остальные CATE-методы. По RMSE он почти совпадает с X-learner и немного лучше S-learner, но по корреляции с истинным CATE уступает X-learner, S-learner и МНК. Значит, как дополнительный метод повышенной сложности R-learner здесь сработал содержательно корректно, но не является однозначно лучшим по всем критериям индивидуальной гетерогенности.

Сравним CATE-оценки с истинными значениями, доступными в симуляции. Это ключевое преимущество учебной постановки: в реальных данных истинный CATE_i недоступен, а здесь мы можем напрямую измерить качество восстановления гетерогенности.

Поэтому далее удобно смотреть не только на отдельные примеры предсказаний, но и на интегральные критерии качества по всей выборке.

Таблица показывает индивидуальные оценки CATE для каждого метода. Для качества сравнения, как и в семинаре, удобно использовать среднеквадратичную ошибку относительно истинного CATE:

$$MSE_0 = \frac{1}{n} \sum_{i=1}^n (CATE_i - \widehat{CATE}_i)^2.$$

Кроме того, полезно смотреть на

$$RMSE = \sqrt{MSE_0}, \quad MAE = \frac{1}{n} \sum_{i=1}^n |CATE_i - \widehat{CATE}_i|,$$

а также на среднее значение предсказанного CATE, его смещение относительно истинного среднего эффекта и корреляцию с истинным CATE. Такой набор метрик позволяет разделить два вопроса: насколько хорошо метод восстанавливает средний уровень эффекта и насколько хорошо он ранжирует клиентов по индивидуальной гетерогенности.

Качество CATE-оценок относительно oracle-CATE

метод	mean CATE	bias mean	RMSE	MAE	corr with true CATE
LS	8034.57	1741.61	2588.92	2119.93	0.617
T-learner	7840.64	1547.68	2503.46	2023.76	0.588
S-learner	7785.13	1492.17	2450.86	1989.37	0.604
CT	7816.84	1523.88	3691.49	2529.43	0.410
X-learner	7751.17	1458.21	2429.07	1966.27	0.605
R-learner	7582.08	1289.12	2431.15	1943.29	0.530

По нашим метрикам лучше всего гетерогенность эффекта по MSE_0 восстанавливает X-learner: у него минимальный $MSE_0 \approx 5.9 \cdot 10^6$ и наименьший RMSE среди рассматриваемых методов. R-learner идет практически рядом по RMSE и имеет меньший MAE, а S-learner также показывает сильный результат. Метод трансформации классов заметно хуже по MSE_0 из-за высокой дисперсии IPW-псевдоисходов.

Содержательно это означает, что для задач, где важна точность индивидуальной величины эффекта, X-learner в этой симуляции выглядит наиболее убедительно по основной MSE-метрике. Если же акцент делать именно на ранжировке клиентов, нужно также смотреть на корреляцию с истинным CATE: по ней лучшим оказывается МНК, а X-learner и S-learner идут близко. Такие оценки можно использовать, например, для показа премиум-офера тем клиентам, у которых предсказанный прирост трат максимален, но решение лучше проверять по нескольким метрикам одновременно.

Дополнительно сравним CATE-оценки с IPW-псевдоисходами. Этот критерий более шумный, но показывает, насколько методы близки к псевдоиндивидуальным эффектам, построенным только на наблюдаемых данных.

Соответствующий критерий имеет вид:

$$MSE_1 = \frac{1}{n} \sum_{i=1}^n (monthly_spending_i^* - \widehat{CATE}_i)^2.$$

MSE1 по IPW-псевдоисходам

метод	MSE1
LS	508965200.00
T-learner	507271700.00
S-learner	509209600.00
CT	478352600.00
X-learner	508492900.00
R-learner	507514900.00

Значения MSE1 по псевдоисходам существенно больше, потому что сами IPW-псевдоисходы имеют высокую дисперсию. Поэтому, как и в семинаре, основной содержательный критерий здесь — это сравнение с истинным CATE, а не только с шумной гроху-целью.

В нашем случае по MSE1 минимальное значение получается у метода трансформации классов, потому что он напрямую обучается на том же IPW-псевдоисходе. Но это не означает, что он лучше восстанавливает истинный CATE: по MSE0 относительно симуляционного oracle-CATE метод CT оказывается худшим. Поэтому главный вывод делаем по MSE0, а MSE1 используем только как дополнительную диагностику близости к шумной гроху-цели.

5.6

Задание. Оцените локальный средний эффект воздействия с помощью: двойного машинного обучения без инструментальной переменной; двойного машинного обучения с инструментальной переменной. Сопоставьте результаты и объясните, в чем в вашем случае будет заключаться различие между средним эффектом воздействия и локальным средним эффектом воздействия. Приведите содержательную экономическую интерпретацию оценки локального среднего эффекта воздействия.

Ответ.

Как и в семинаре, здесь важно отделить проблему ATE от проблемы LATE. При наличии эндогенности без инструмента можно пытаться оценивать ATE только при очень сильной предпосылке условной независимости. Если же эта предпосылка нарушена, то инструментальный подход позволяет идентифицировать не средний эффект для всех клиентов, а локальный средний эффект для наблюдателей.

Сначала построим DML без инструмента. Технически это DoubleMLIRM, поэтому он оценивает ATE при условной независимости, а не полноценный LATE. Без инструментальной переменной локальный эффект для наблюдателей в том же смысле, что и IV-LATE, не идентифицируется. Поэтому этот результат используется ниже как ATE/DML-бенчмарк без инструмента: он показывает, что дает causal ML при игнорировании инструментальной структуры, но не является самостоятельной оценкой LATE.

Перед DML-оценками зафиксируем важную техническую деталь сравнения. Истинные ATE и LATE выше рассчитаны на полной выборке из 30000 наблюдений, а DML-оценки ниже строятся на рабочей подвыборке из 10000 наблюдений. Поэтому в таблицах дальше full-sample эффекты остаются главным эталоном DGP, но для контроля также выводим oracle-эффекты на самой рабочей подвыборке.

Oracle-эффекты на полной выборке и рабочей подвыборке

параметр	полная выборка 30000	рабочая подвыборка 10000
ATE oracle	6292.96	6324.95
LATE oracle	6280.32	6328.99
ATET oracle	7274.64	7285.16

DML без инструмента в 5.6

показатель	значение
ATE/DML no IV benchmark	7810.00
std err	74.435
95% CI lower	7664.11
95% CI upper	7955.89

Оценка без инструмента показывает, что будет получено, если игнорировать инструментальную структуру и опираться только на наблюдаемые признаки. В нашем случае это дает число ≈ 7810 . Его нельзя интерпретировать как LATE: это бенчмарк для среднего эффекта при условной независимости. Однако сравнение с oracle-LATE полезно диагностически: результат заметно выше как full-sample oracle LATE = 6280, так и sample oracle LATE ≈ 6329 .

Следовательно, если не учитывать эндогенность подписки и не использовать инструмент, оценка эффекта оказывается завышенной относительно локального эффекта для наблюдателей. Это ровно та проблема, ради которой в следующем шаге и нужен IV-DML.

Ответ. Теперь используем DoubleMLIIVM, где `free_trial_banner` выступает инструментом для премиум-подписки. Эта модель оценивает LATE для наблюдателей.

В инструментальном подходе DoubleMLIIVM используются три nuisance-объекта:

$$\begin{aligned}
 g(Z_i, X_i) &= E(\text{monthly_spending}_i \mid X_i, \text{free_trial_banner}_i = Z_i), \\
 m(X_i) &= P(\text{free_trial_banner}_i = 1 \mid X_i), \\
 r(Z_i, X_i) &= P(\text{premium_subscription}_i = 1 \mid X_i, \text{free_trial_banner}_i = Z_i).
 \end{aligned}$$

При выполнении условий релевантности, экзогенности и монотонности инструмента DoubleMLIIVM оценивает именно локальный средний эффект воздействия. Иными словами, он отвечает на вопрос: каков эффект подписки для тех клиентов, чье решение о подписке действительно меняется из-за баннера.

Перед оценкой IV-DML проверим first stage и состав типов клиентов. Баннер должен заметно менять вероятность подписки, а наблюдатели должны иметь ненулевую долю; это поддерживает релевантность инструмента и содержательную интерпретацию LATE. Доли типов клиентов (Complier, Always taker, Never taker) являются oracle-диагностикой из симуляционной DGP: в реальных данных они напрямую не наблюдаются. Observed first-stage difference может не совпадать с oracle-долей compliers, потому что сравнение $P(D=1 \mid Z=1) - P(D=1 \mid Z=0)$ считается по фактически получившим и не получившим баннер на конечной подвыборке, где состав групп по X может отличаться.

First-stage и oracle-типы клиентов

показатель	оценка
$P(D=1 \mid Z=0)$	0.411
$P(D=1 \mid Z=1)$	0.648
first-stage difference	0.237
share Complier	0.162
share Always Taker	0.438
share Never Taker	0.400

IV-DML

показатель	значение
LATE dml IV	6250.16
std err	572.89
95% CI lower	5127.31
95% CI upper	7373.02

IV-DML оценивает эффект не для всех клиентов, а для наблюдателей, то есть для той подгруппы, чье решение о подписке изменяется под воздействием баннера. В наших данных оценка LATE dml IV равна примерно 6250. По сравнению с full-sample oracle LATE = 6280 абсолютное отклонение составляет около 30; по сравнению с sample oracle LATE $\approx$ 6329 отклонение составляет около 79.

Оба сравнения намного лучше бенчмарка без инструмента ($\approx$ 1530 относительно full-sample LATE и $\approx$ 1481 относительно sample LATE). Значит, именно введение инструмента радикально улучшает качество оценки локального эффекта. Экономически это означает, что баннер позволяет выделить клиентов, для которых подписка действительно является маргинальным решением, и именно для них эффект подписки можно оценить особенно содержательно.

Повышенная сложность. Ответ. Поскольку Rscript и пакет switchSelection в текущей среде недоступны, оценим параметрический benchmark без R: two-step endogenous switching model в Python. Это не полноценная реализация switchSelection/FIML и ниже не оцениваются стандартные ошибки switching-модели, поэтому результат используется именно как параметрическая точка сравнения.

На первом шаге оценивается параметрическое selection equation через probit:

$$premium_subscription_i^* = \alpha_0 + \alpha_1 free_trial_banner_i + X_i' \alpha + u_i, \quad premium_subscription_i = 1[premium_subscription_i^* > 0].$$

На втором шаге отдельно для клиентов с подпиской и без подписки оцениваются outcome-equations с поправкой Хекмана через inverse Mills ratio:

$$\begin{aligned} monthly_spending_i &= X_i' \beta_1 + \rho_1 \sigma_1 \lambda_1(X_i, Z_i) + \varepsilon_{1i}, & D_i &= 1, \\ monthly_spending_i &= X_i' \beta_0 + \rho_0 \sigma_0 \lambda_0(X_i, Z_i) + \varepsilon_{0i}, & D_i &= 0. \end{aligned}$$

Это параметрический подход: и модель выбора режима, и модели исходов задаются явной функциональной формой. По сравнению с IV-DML он лучше интерпретируется, но сильнее зависит от корректности probit-спецификации и линейных outcome-equations.

Параметрический switching benchmark

показатель	оценка
share negative raw complier weights	0.0000
share clipped or near-zero weights	0.0000
mean raw complier weight	0.160
mean clipped complier weight	0.160
sum clipped complier weights	1601.94
LATE parametric switching	8027.34
parametric switching - true LATE	1747.02

По параметрической switching-модели получаем предсказанные потенциальные исходы $\widehat{monthly_spending}_{1i}$ и $\widehat{monthly_spending}_{0i}$, а затем индивидуальный параметрический эффект

$$\hat{\tau}_i = \widehat{monthly_spending}_{1i} - \widehat{monthly_spending}_{0i}.$$

Чтобы приблизиться именно к локальному эффекту для наблюдателей, используем параметрические complier weights:

$$\hat{c}_i = \widehat{P}(\text{premium_subscription}_i = 1 \mid \text{free_trial_banner}_i = 1, X_i) - \widehat{P}(\text{premium_subscription}_i = 1 \mid \text{free_trial_banner}_i = 0, X_i).$$

Тогда итоговая параметрическая оценка имеет вид

$$\widehat{LATE}^{param} = \frac{\sum_i \hat{c}_i \hat{\tau}_i}{\sum_i \hat{c}_i}.$$

Если из-за численных ошибок некоторые веса оказываются отрицательными, мы клиппируем их к нулю. Такая процедура делает интерпретацию весов как вероятностной меры принадлежности к наблюдателям более устойчивой.

Сравнение LATE-оценок

метод	оценка	estimate - true LATE
ATE	6292.96	12.641
LATE oracle	6280.32	0.0000
ATE/DML no IV benchmark	7810.00	1529.68
LATE dml IV	6250.16	30.159
LATE parametric switching	8027.34	1747.02

ATE относится ко всем клиентам, а LATE — только к наблюдателям. В данном исследовании LATE показывает эффект премиум-подписки для клиентов, которых можно подтолкнуть к подписке показом баннера. Поэтому строка ATE/DML no IV benchmark в таблице выше не является оценкой LATE; она оставлена только как сравнение с подходом, который не использует инструмент и опирается на условную независимость по наблюдаемым признакам.

Параметрический switching benchmark дает оценку того же локального эффекта через жесткую функциональную форму: probit для выбора подписки и две линейные outcome-модели с поправкой на selection. В отличие от IV-DML, этот подход менее гибкий и чувствителен к спецификации, зато его легче интерпретировать как явную структурную модель выбора режима и исходов. Поскольку это ручная two-step-реализация без стандартных ошибок и без полноценного switchSelection, результат следует использовать только как иллюстративный параметрический benchmark, а не как надежную финальную оценку. Большое отклонение от oracle LATE показывает, что в этой DGP линейная switching-спецификация недостаточно хорошо приближает истинный механизм.

5.7

Задание. Оцените средние эффекты воздействия и локальные средние эффекты воздействия используя худшие из обученных классификационных и регрессионных моделей. Сопоставьте результаты с теми, что были получены с помощью лучших моделей. Сделайте вывод об устойчивости результатов к качеству используемых методов машинного обучения.

Ответ.

В этом пункте, как и в семинаре, сохраняются те же формулы для T-learner, IPW, DR, DML и IV-DML, но nuisance-модели заменяются худшими по качеству из предыдущих разделов.

В разделе 3 худший классификатор из основных методов выбран по минимальному AUC на тестовой выборке: это логистическая регрессия (AUC = 0.729) с параметрами после тюнинга по accuracy C = 0.01, penalty = 'l2'. В разделе 4 худшая регрессионная модель из основных методов выбрана по максимальному RMSE на тестовой выборке после тюнинга: это МНК (RMSE test = 4983.14), реализованный как LinearRegression без дополнительных гиперпараметров. Как и в пункте 5.4, в блоке 5 эти модели переобучаются на causal controls без free_trial_banner.

Такая замена позволяет проверить, насколько чувствительны оценки ATE и LATE к ошибкам прогнозирования условных средних и вероятностей. Если метод устойчив, то замена лучших моделей на худшие не должна полностью менять качественный вывод. Если же оценка резко меняется, это означает сильную зависимость итогового causal-вывода от качества вспомогательных ML-моделей.

Повторим T-learner, IPW, DR, DML и IV-DML с худшими nuisance-моделями. Для IPW/DR отдельно проверяем диапазон propensity score: если вероятность близка к 0 или 1, веса становятся большими и оценки могут быть нестабильными.

Худшая propensity-модель: диапазон вероятностей

показатель	оценка
worst min prob	0.073
worst max prob	0.992

Для DML-оценок отдельно создадим объекты DoubleMLData и применим худшие модели как nuisance-оценки.

Сопоставим оценки, полученные лучшими и худшими моделями. Это позволяет отделить два уровня неопределенности: собственно эконометрическую идентификацию и качество статистического приближения nuisance-объектов.

В наших результатах ATE-оценки при переходе к худшим моделям в целом сдвигаются вверх, а инструментальная LATE DML IV меняется особенно заметно: примерно с 6250 до 8450. Следовательно, в этой симуляции IV-DML чувствителен к качеству вспомогательных моделей, потому что в нем одновременно участвуют outcome-model, treatment-model и instrument-model. Этот вывод относится именно к реализации с выбранными nuisance-моделями и не отменяет того, что инструментальная идентификация остается ключевой для работы с эндогенностью.

Устойчивость к качеству nuisance-моделей

метод	лучшие модели	худшие модели
ATE ls	8034.57	8034.57
ATE conditional means	7840.64	8034.57
ATE IPW	7816.84	7914.96
ATE DR	7819.54	8065.18
ATE DML	7810.00	8064.23
LATE DML IV	6250.16	8450.27

Оценки ATE заметно меняются при переходе к худшим nuisance-моделям, что говорит о чувствительности результатов к качеству прогнозных моделей. Строка ATE ls не меняется, потому что худшая регрессионная модель и есть линейная регрессия/МНК, то есть тот же estimator, который используется в LS-бенчмарке. У худшего propensity максимальная вероятность близка к 1 (0.992), поэтому IPW/DR с худшими моделями потенциально менее устойчивы из-за больших обратных весов. Для LATE через IV-DML различие также может быть существенным, потому что инструментальная модель требует одновременно хороших моделей исхода, воздействия и инструмента.

5.8

Задание. Резюмируйте ключевые выводы проведенного в данном разделе анализа.

Ответ.

Соберем итоговые таблицы раздела, а затем содержательно интерпретируем их с точки зрения ATE, CATE, LATE и устойчивости методов.

Итоговые таблицы блока 5

ATE

метод	оценка
ATE oracle	6292.96
ATE naive	9883.19
ATE ls	8034.57
ATE conditional means	7840.64
ATE dml standard	7810.00
ATE IPW	7816.84
ATE DR	7819.54
ATE PSM	8019.06

CATE MSE0

метод	MSE0
LS	6702512.00
T-learner	6267289.00
S-learner	6006731.00
CT	13627120.00
X-learner	5900400.00
R-learner	5910478.00

LATE

метод	оценка	estimate - true LATE
ATE	6292.96	12.641
LATE oracle	6280.32	0.0000
ATE/DML no IV benchmark	7810.00	1529.68
LATE dml IV	6250.16	30.159
LATE parametric switching	8027.34	1747.02

Проведенный анализ дает несколько важных выводов.

Во-первых, премиум-подписка оказывает положительный причинный эффект на месячные траты клиентов. Истинный ATE в симуляции на полной объединенной выборке равен примерно 6293, а истинный LATE — 6280, так что для наблюдателей эффект близок к среднему эффекту по выборке.

Во-вторых, наивная оценка сильно завышает эффект (9883 против 6293) из-за самоотбора. Это подтверждает, что простое сравнение клиентов с подпиской и без подписки неприменимо, когда существует ненаблюдаемая переменная, одновременно влияющая и на treatment, и на outcome.

В-третьих, методы из пункта 5.4, основанные на наблюдаемых признаках, действительно сокращают смещение, но не устраняют его полностью. Оценки остаются выше эталона, поскольку предпосылка условной независимости нарушается скрытой online_preference.

В-четвертых, для оценки гетерогенности эффекта лучшим методом по MSE0 оказывается X-learner; R-learner идет почти наравне по RMSE и имеет наименьшее смещение среднего эффекта. При этом для задачи ранжировки важно помнить, что по корреляции с истинным CATE лучшим оказывается МНК, поэтому таргетирование лучше оценивать не по одной метрике. Метод трансформации классов работает хуже по MSE0 из-за высокой дисперсии псевдоисходов, хотя по MSE1 он ближе всего к собственному IPW-псевдоисходу.

В-пятых, при наличии эндогенности принципиально важен инструментальный подход. Бенчмарк DML без инструмента не является оценкой LATE, потому что без инструмента локальный эффект для наблюдателей не

идентифицируется в том же смысле. Он заметно расходится с true LATE, тогда как IV-DML дает оценку гораздо ближе к локальному эффекту для наблюдателей. Параметрический switching benchmark дает дополнительную точку сравнения, но заметно сильнее ошибается из-за жестких функциональных предпосылок.

Наконец, проверка устойчивости показывает, что качество nuisance-моделей действительно важно. При переходе к худшим моделям меняются и ATE, и особенно LATE через IV-DML. В этом блоке лучшие/худшие модели трактуются как модели из основной sklearn-линейки и переобучаются на causal controls без free_trial_banner; внешний CatBoost из повышенной сложности блока 4 не используется как nuisance-модель ради сопоставимости с семинарскими методами. Параметрический switching benchmark также не является полноценным switchSelection, поэтому используется только как иллюстративное сравнение с IV-DML. Поэтому общий практический вывод такой: causal-методы машинного обучения полезны и информативны, но их результат нужно интерпретировать вместе с предпосылками идентификации, качеством вспомогательных прогнозных моделей и ограничениями выбранной спецификации.

5.9

Задание. В случае необходимости проведите дополнительный анализ.

Ответ.

Дополнительный анализ в данном разделе не требуется. Основные оценки ATE, CATE и LATE, а также проверка устойчивости к качеству моделей уже проведены. Отдельно была добавлена повышенная сложность с PSM, R-learner и параметрическим switching benchmark, поэтому содержательно раздел покрывает как базовые, так и расширенные подходы к оцениванию эффектов воздействия.